部分観測環境における意思決定のための履歴表現学習

早稲田大学　大和書房株式会社

2026-10-06

研究の背景・目的

強化学習が扱ってきた意思決定

強化学習はこれまで、結果を考えながら行動を選択する意思決定問題を扱ってきた

囲碁やゲームなどでは、人間を上回る性能の獲得にも成功している

（囲碁とかゲーム、ロボティクスの図）

強化学習の基本

エージェントが環境の状態を見て行動し、その結果として報酬を得る相互作用

この相互作用を繰り返し、状態・行動の価値を学習し、より高い価値につながる行動を選択する

（エージェントと環境が循環して行動と報酬を受け取り合うブロック図＋Q-tableを作り上げる図）

状態の把握は難しい

しかし部分観測環境では、現在の観測だけではエージェントが置かれている状態を正確に把握できない

（部分観測迷路の図）＋ 次はどこに行くべきなのか？）

履歴を参照することで状態を推測

履歴を参照すれば現在の状態をより正確に把握でき、適切な行動を選択できる

（異なる経路を辿って同じ場所にたどり着いた図、次はこっちに行けばいいことがわかる、ことを示す）

履歴の扱い方に注意が必要

部分観測環境では履歴が必要だが、そのまま扱うだけでは非常に多い学習量が必要

（不要な違いまで区別すると別の履歴として学習してしまうの図）　（履歴が長いとどの行動が結果につながったのかが学習するのが難しいの図）

研究目的

複雑な環境を必要な意味ごとの状態へ整理し、扱いやすく捉え直すことで効率的な 学習を可能したい

（似たような履歴を同じとして扱うの図）　（意味ごとの遷移として表現するの図）

関連研究

履歴から状態を表現する

履歴から将来の予測や意思決定に必要な情報を持つ状態表現を学習する

長い履歴そのものを使うのではなく、必要な情報だけに圧縮する

図 （履歴⇒エンコーダー、、、？） （単純なPSRの話）

細かすぎる履歴を圧縮

細かすぎる状態を特定の情報について一つにまとめて処理することができる

図（元の履歴空間と潜在空間でまとまってる感じの図）

状態だけをまとめると行動選択が衝突する

しかし、意思決定上同じ意味を持つ履歴を同じ状態にまとめてもその状態で必要な具体行動が異なる場合、1つの方策では行動を決められない

状態と行動を同時に抽象化する

状態だけでなく行動も同時に対応付けることで、異なる具体的な制御を同じ抽象的な意思決定として扱う

（マルコフ決定過程準同型(MDP homomorphism)の図）

従来手法での抽象化

部分観測環境では扱えないような抽象化を行なっている

- 左右、上下対称な状態をまとめる抽象化
- 目的地までの距離が同じ状態をまとめる

本題

研究目標

複雑な履歴を意思決定上の意味ごとの状態へ整理し、その状態を利用して効率的に探索・学習できるようにする （探索→履歴集め→履歴の抽象化→探索の効率化）

そのために目指す抽象化

細かな履歴や具体的な行動が異なっていても将来の価値が似た経験を共通の表現としてまとめる

実験設定

モデル全体

モデル比較

モデル比較

実験結果

実験結果

実験結果

まとめと今後の展望

参考文献