潜在表現の分解・可視化による予測の説明

貫井 俊吾

2026-05-20

背景

高精度なAIからの知識抽出

近年の画像認識モデルは人間よりも高精度に予測を行う

そのようなモデルの予測根拠を知ることで未知の知見を獲得できる



CNN

年齢

予測根拠を人間にわかる形で提示し知識抽出

関連研究

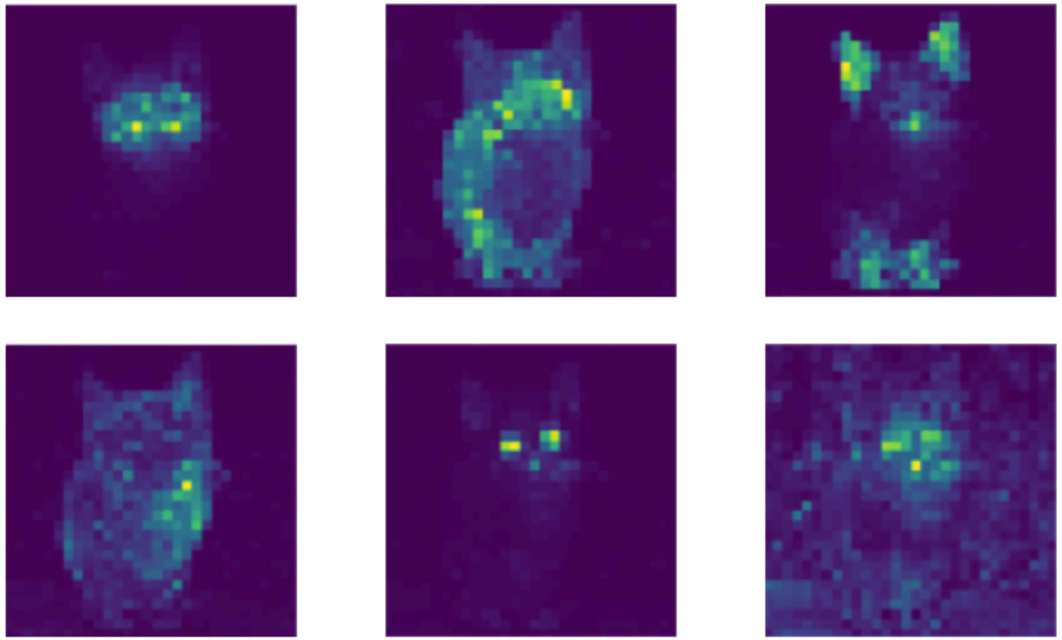
XAI: AIの捉えた情報を可視化する技術

NNの予測を説明するための説明可能AI(XAI)という技術がある

モデルの入力が予測に対してどの程度重要かを可視化することで説明



x



ViTが画像を猫と判断した時の根拠の例

XAI手法の分類

提案されている手法は以下のような軸で分類することができる

- 透明性/事後性
- 大域性/局所性
- モデル依存性/モデル非依存性

先行手法のほとんどが事後的、局所的なものでありヒートマップによって根拠を提示

モデル依存性を持たないXAI手法

モデル依存性を持たないものとして以下のようなものが挙げられる

- 協力ゲーム理論に基づく手法(SHAP)
- 代理モデルに基づく手法(LIME)
- 事例に基づく手法(influence function)

協力ゲーム理論に基づく手法: SHAP

説明変数(プレイヤ)iの参加により起こる結果の変化の平均値を貢献度(shapley値)とする

プレイヤ	報酬
$\emptyset$	0
{1}	10
{2}	20
{3}	30
{1,2}	60
{2,3}	70
{1,3}	90
{1,2,3}	100

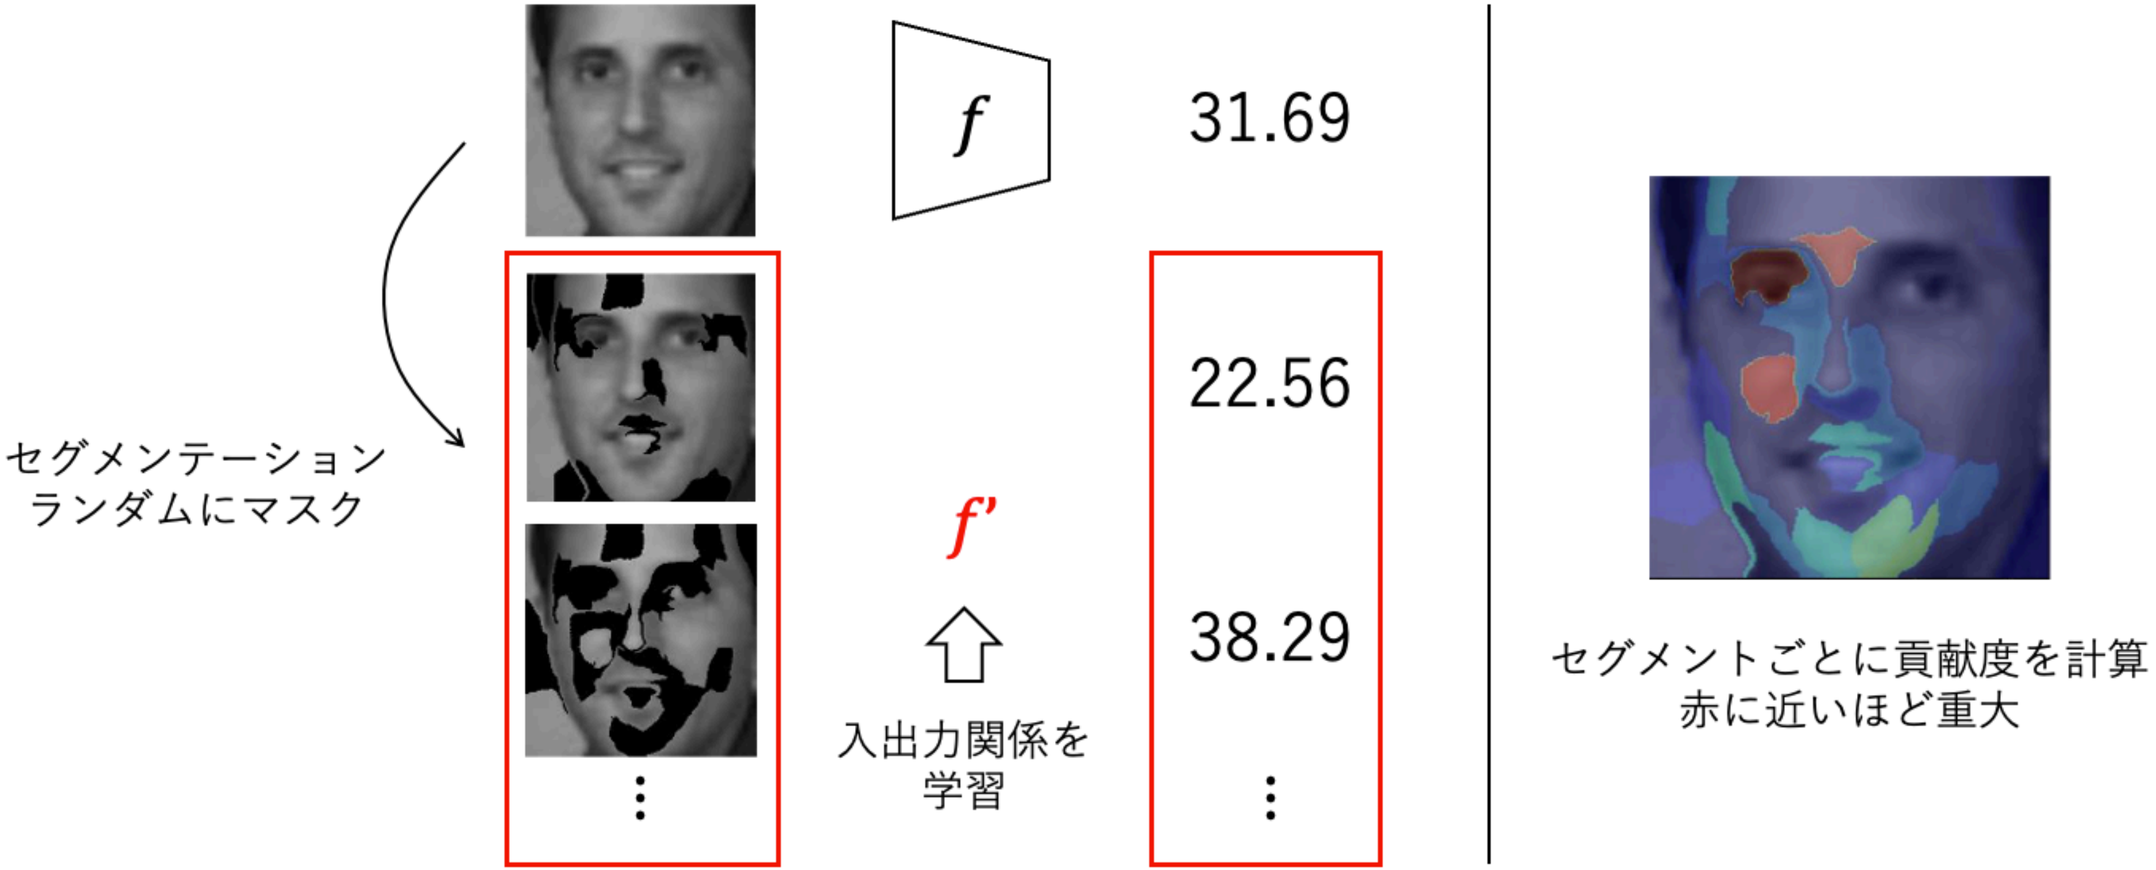
プレイヤが協力して得られる報酬

#	参加順	プレイヤ1	プレイヤ2	プレイヤ3
1	$\emptyset \to 1 \to 1,2 \to 1,2,3$	10	50	40
2	$\emptyset \to 1 \to 1,3 \to 1,2,3$	10	10	80
3	$\emptyset \to 2 \to 1,2 \to 1,2,3$	40	20	40
4	$\emptyset \to 2 \to 2,3 \to 1,2,3$	30	20	50
5	$\emptyset \to 3 \to 1,3 \to 1,2,3$	60	10	30
6	$\emptyset \to 3 \to 2,3 \to 1,2,3$	30	40	30
shapley値	-	30	25	45

あり得るプレイヤの参加順と変化する貢献度

代理モデルに基づく手法: LIME

対象のモデルfの入出力関係を透明性の高い代理モデルf'で近似する



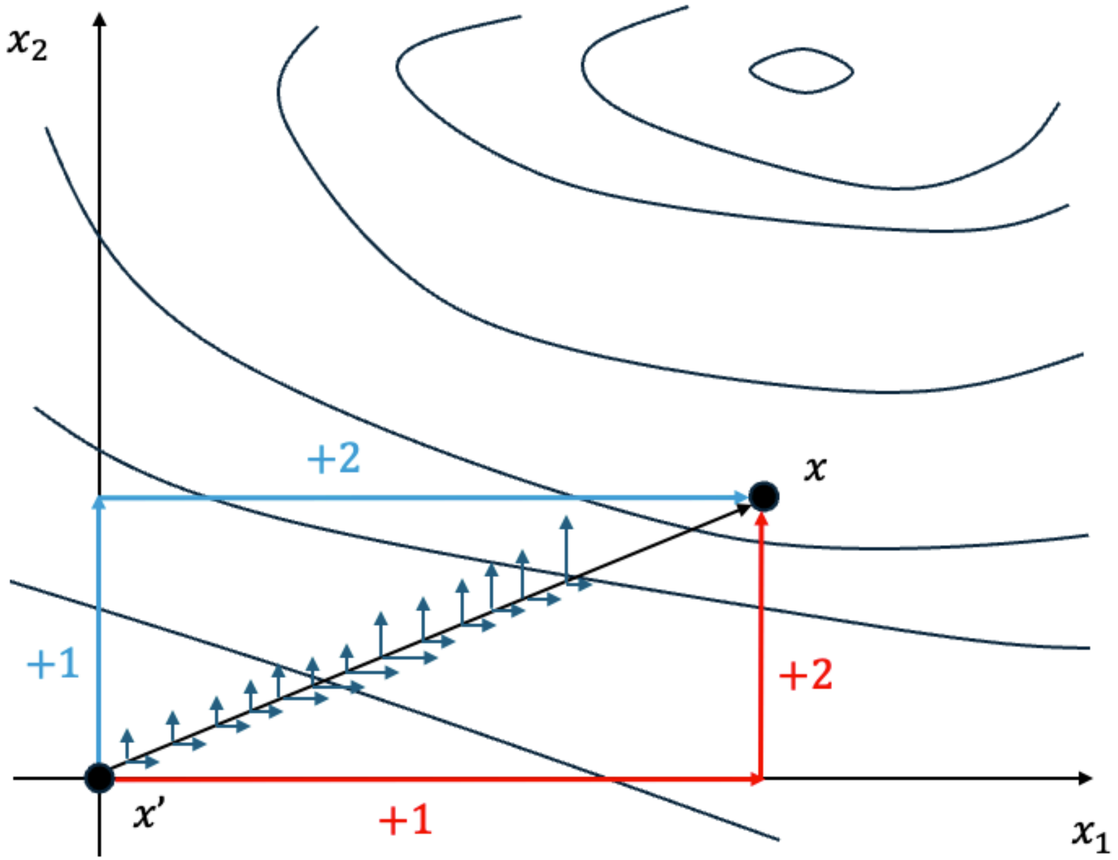
モデル依存性を持つ　XAI手法

モデル依存性を持つ手法として以下が挙げられる

- 逆伝搬に基づく手法(IG, DeepLIFT, LRP, DeconvNet)
- 特徴マップに基づく手法(GradCAM)
- 摂動に基づく手法(PDA)

逆伝搬に基づく手法: Integrated Gradient

baselinex'から対象入力xまでを結ぶ経路上で，モデル出力の入力勾配を線積分することで各入力特徴の出力への寄与を求める手法



説明変数が増えるとSHAPは使えない

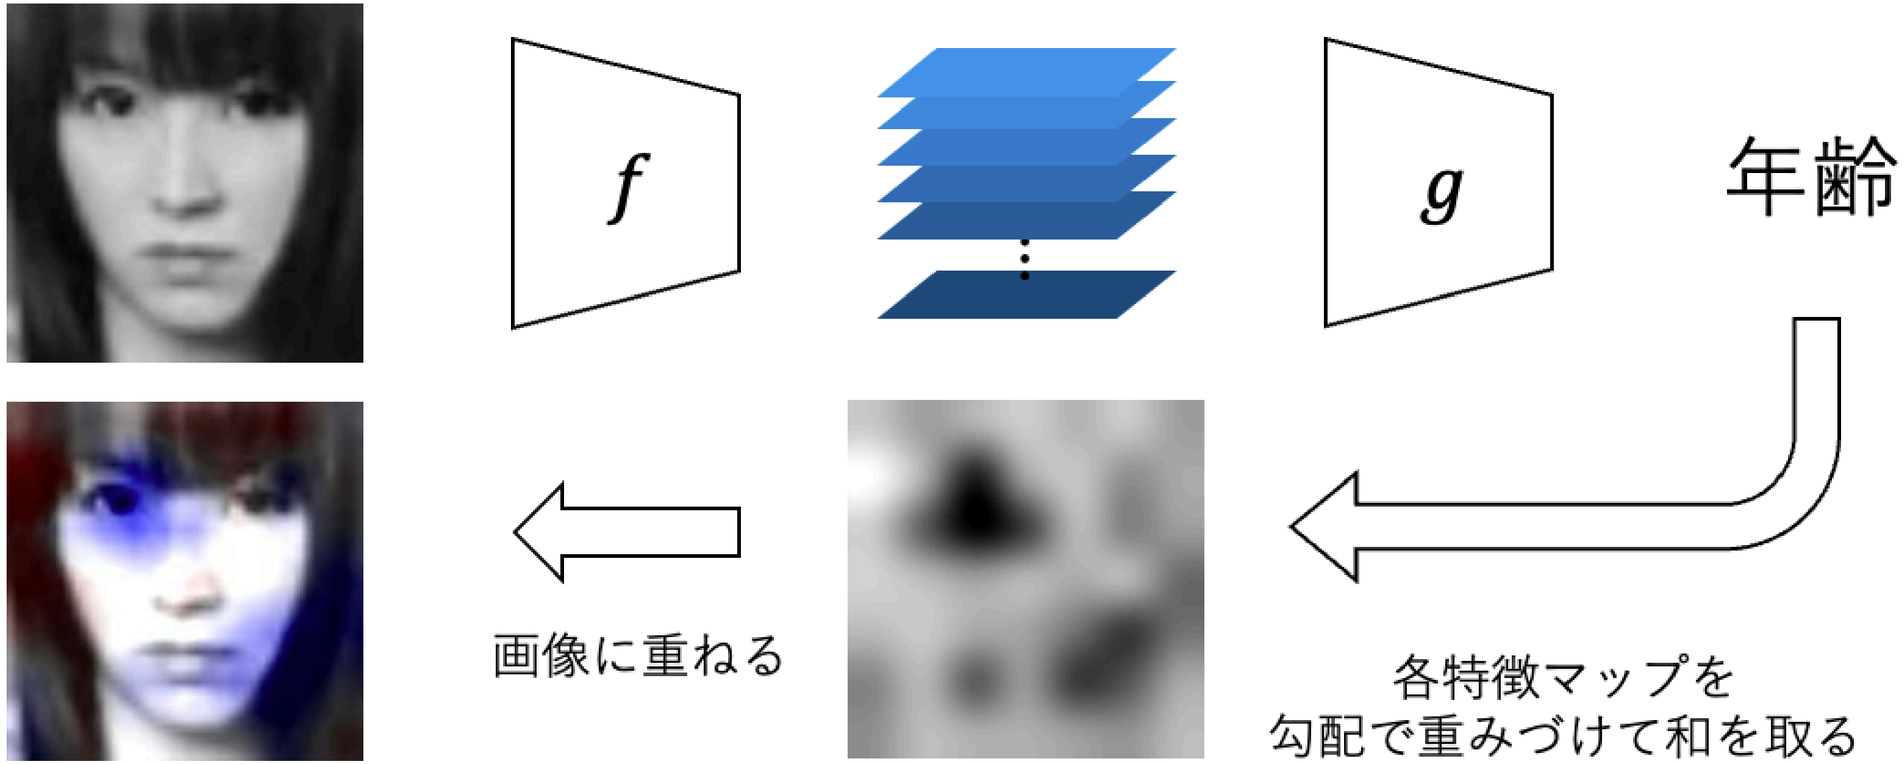
x'からxの経路上での勾配を貢献度と考える



年齢予測タスクへのIGの説明

特徴マップに基づく手法: GradCAM

各特徴マップを予測への勾配で重みづけて線形和をとったものを貢献度のマップとする手法



NNの各素子が持つ情報を確認する手法

予測を直接説明はしないが、NNの任意の素子が持つ情報を知るための
activation maxmizationという手法もある

この手法ではある素子の活性値が最大となるような入力特徴量を求める

※実験ではうまくできなかったので図はgoogle Figure.6 より引用

従来手法では出来上がった要因マップを解釈

画像処理モデルでは入力変数(画素)が意味を持たない

各画素の貢献度をまとめた要因マップが人間の背景知識と合致するかで説明をしている

-> モデルからの知識抽出をするには説明力不足

本題(仮)

研究目標: 入力内の特徴を単位とした予測の説明

画素単位ではなく特徴単位で予測の説明を行いたい

◯ 課題

1. どのように特徴を分解するのか

-> 予測に必要な特徴が抽出される潜在表現を利用

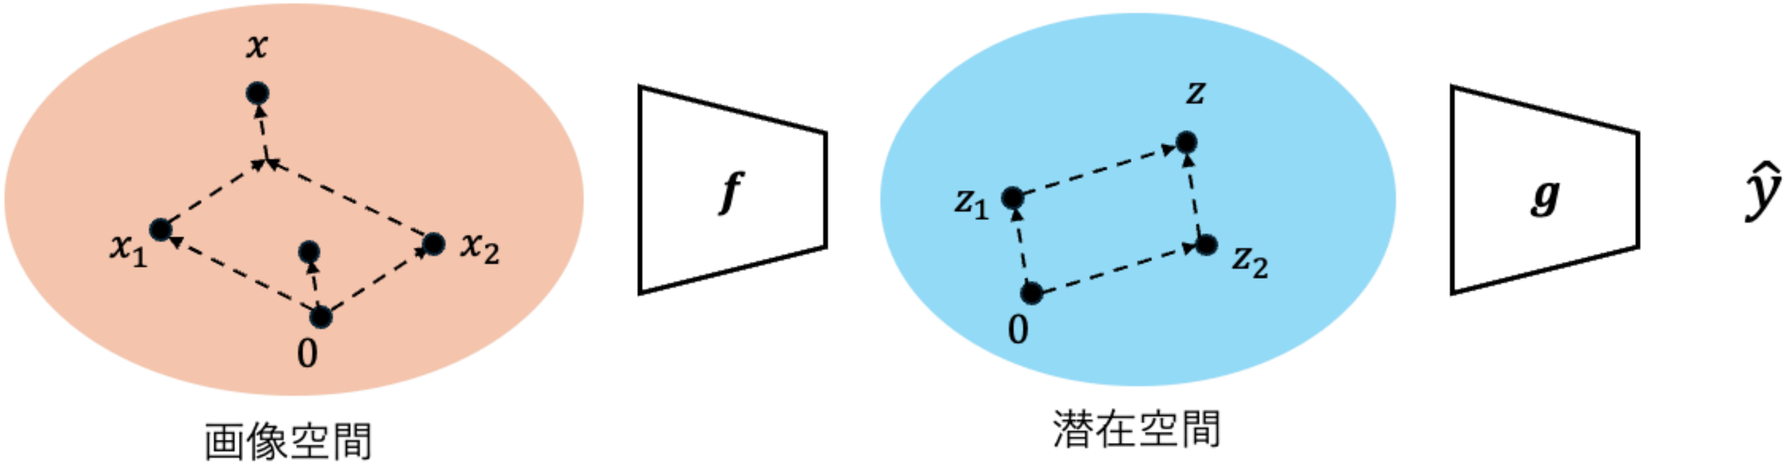
2. 得られた特徴表現をどのように画像に戻すのか

提案手法の流れ

1. 特徴抽出器fにより潜在表現Zを計算

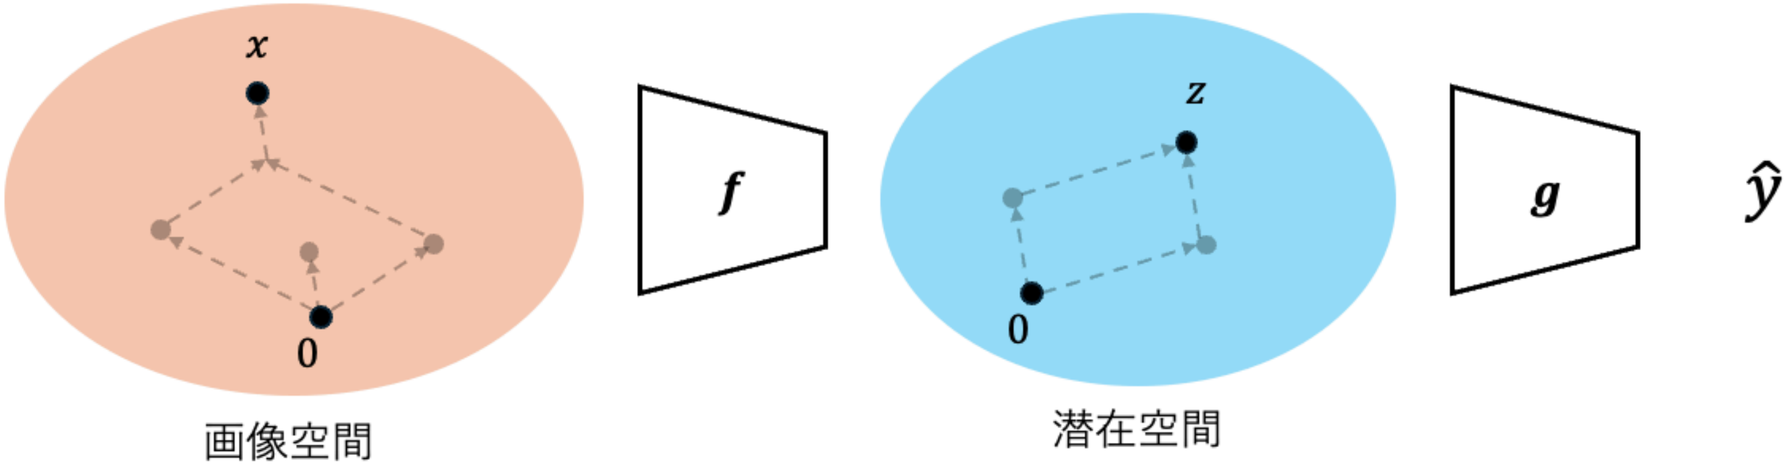
2. Zを実際の入力画像内の特徴Sごとに分解

3. 各特徴s_iに各要素が対応付くように入力画像Xを分解



手法全体の流れ

1. 特徴抽出器fにより潜在表現Zを計算
2. Zを実際の入力画像内の特徴Sごとに分解
3. 各特徴s_iに各要素が対応付くように入力画像Xを分解



1. 特徴抽出器fによる潜在表現Zの計算

本研究ではVGG16というモデルを用いる

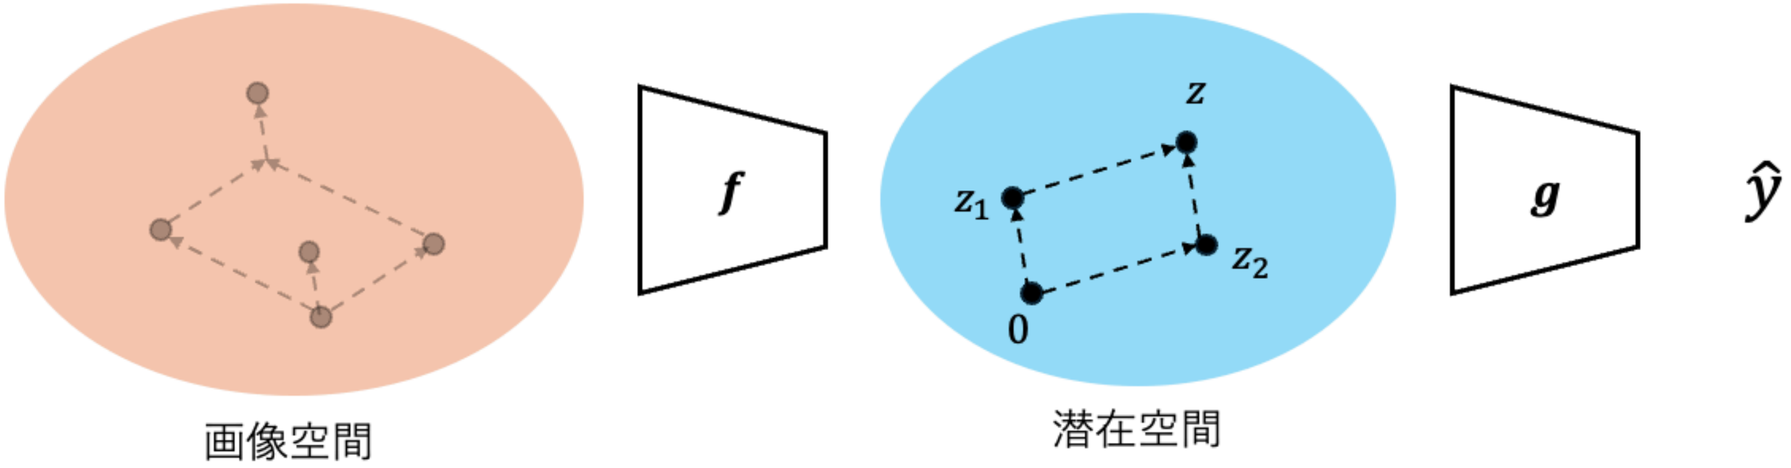
このモデルでは、7×7の特徴マップが512チャネル得られる

手法全体の流れ

1. 特徴抽出器fにより潜在表現Zを計算

2. Zを実際の入力画像内の特徴Sごとに分解

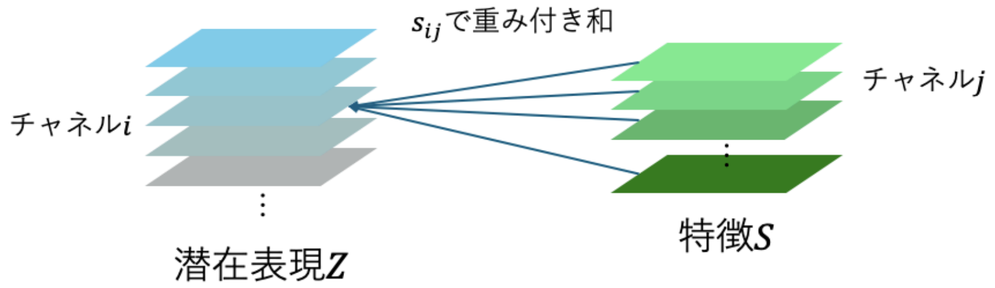
3. 各特徴s_iに各要素が対応付くように入力画像Xを分解



2. Zを実際の入力画像内の特徴Sごとに分解

各チャネルz_iが独立な特徴s_jの線形混合で表現されると仮定

$$z_i = \sum_{j=1}^{n} a_{ij} s_j$$

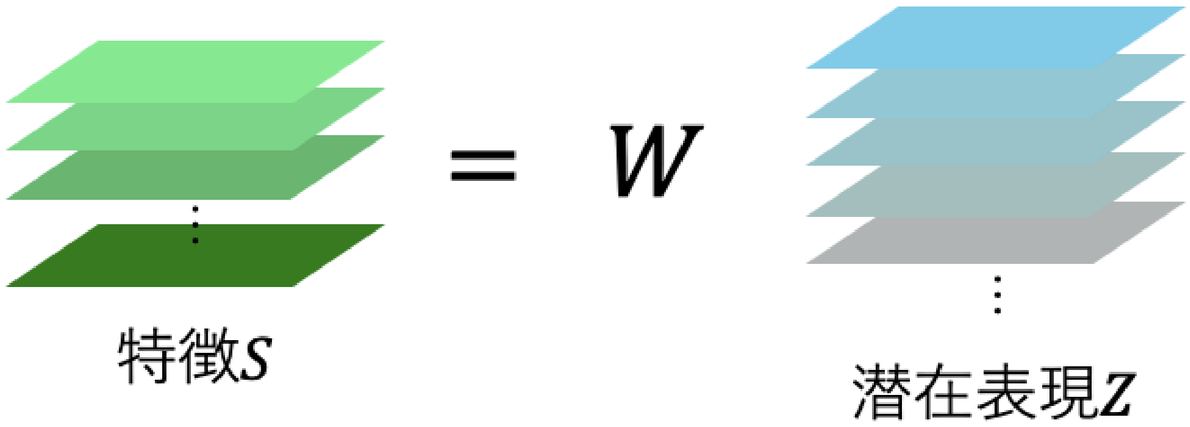


現在は独立成分分析で特徴の推定をしようとしている

独立成分分析

分離した特徴を独立にするように分離行列を最適化する手法

分離された信号(独立成分)の独立性の測り方は手法による



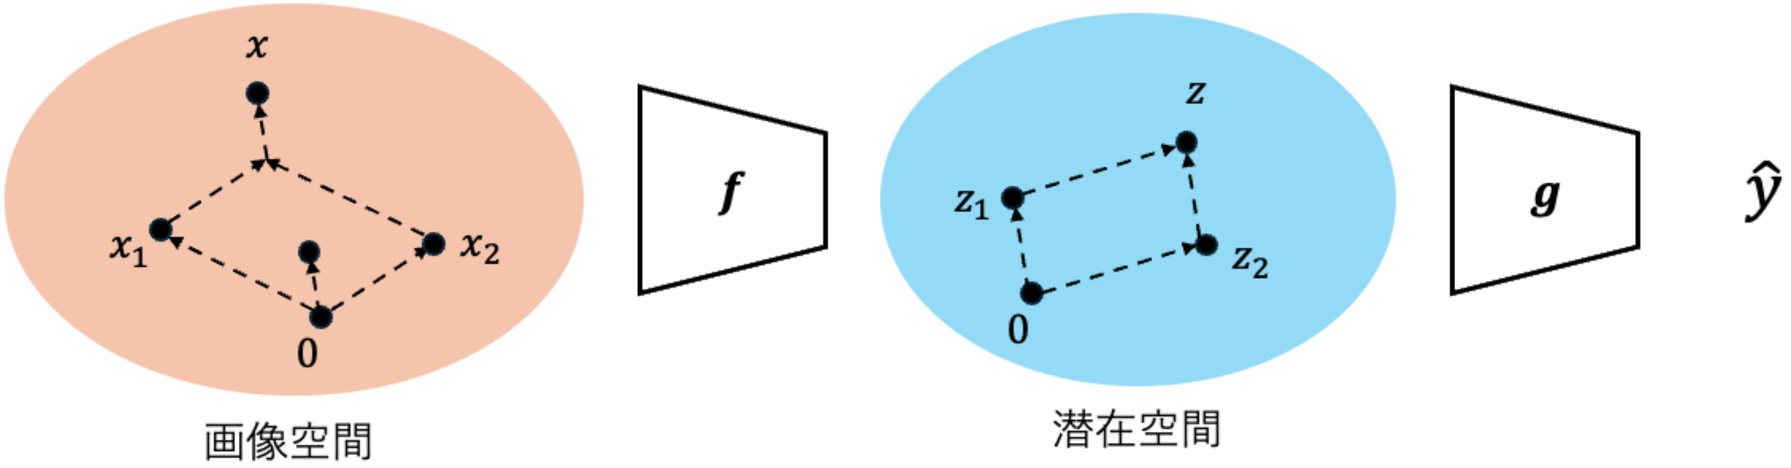
Sの各チャネルが独立になるようにWを最適化

手法全体の流れ

1. 特徴抽出器fにより潜在表現Zを計算

2. Zを実際の入力画像内の特徴Sごとに分解

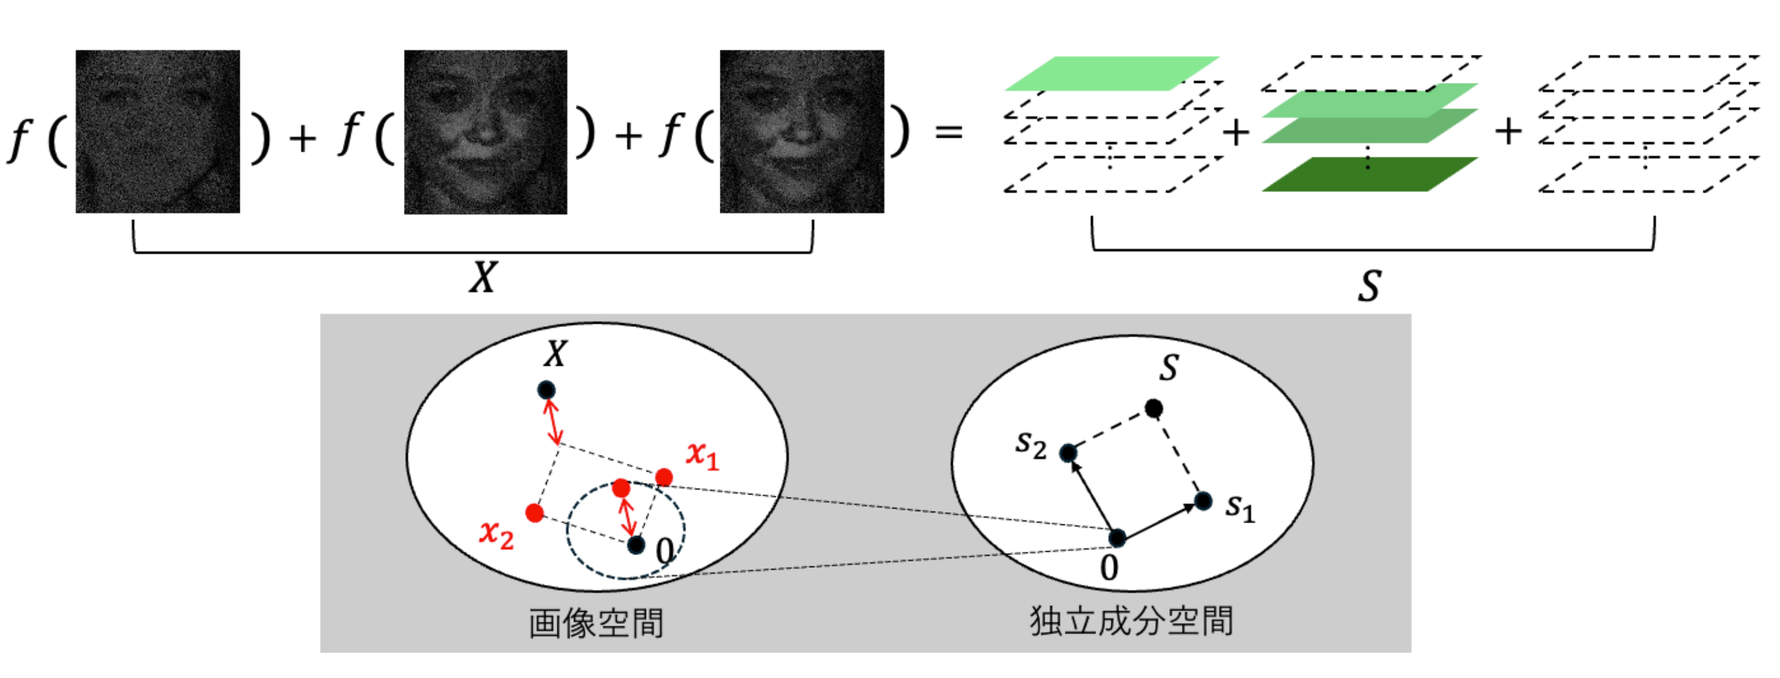
3. 各特徴s_iに各要素が対応付くように入力画像Xを分解



各特徴s_iに各要素が対応付くよう入力画像Xを分解

$Wf(x_i) = s_i$を満たすようにx_iを最適化する

このとき、$\sum_i x_i = X$、$f(x_{null}) = \mathbf{0}$を満たすようにする



特徴分解(独立成分分析)について

特徴分解の目的

特徴分解では、

- 次元削減により可視化する情報を減らす
- 潜在表現の中で絡み合った情報をばらばらにする

ということを目的としている

現在は独立成分分析を用いて実験中

独立成分分析

独立成分分析は、観測信号から未知の信号元を推定する方法

以下のような手順を踏む

1. 観測信号を白色化し、無相関(平均0、分散1)にする
2. 無相関な信号が独立になるよう適切な回転を推定する

独立性の定義や最適化法でさまざまな種類がある

独立成分分析(1): 白色化

白色化は、PCAにより得られた固有ベクトル方向Eに観測信号zを射影して無相関化し、固有値Dの平方根の逆数でスケーリングして分散1に揃える

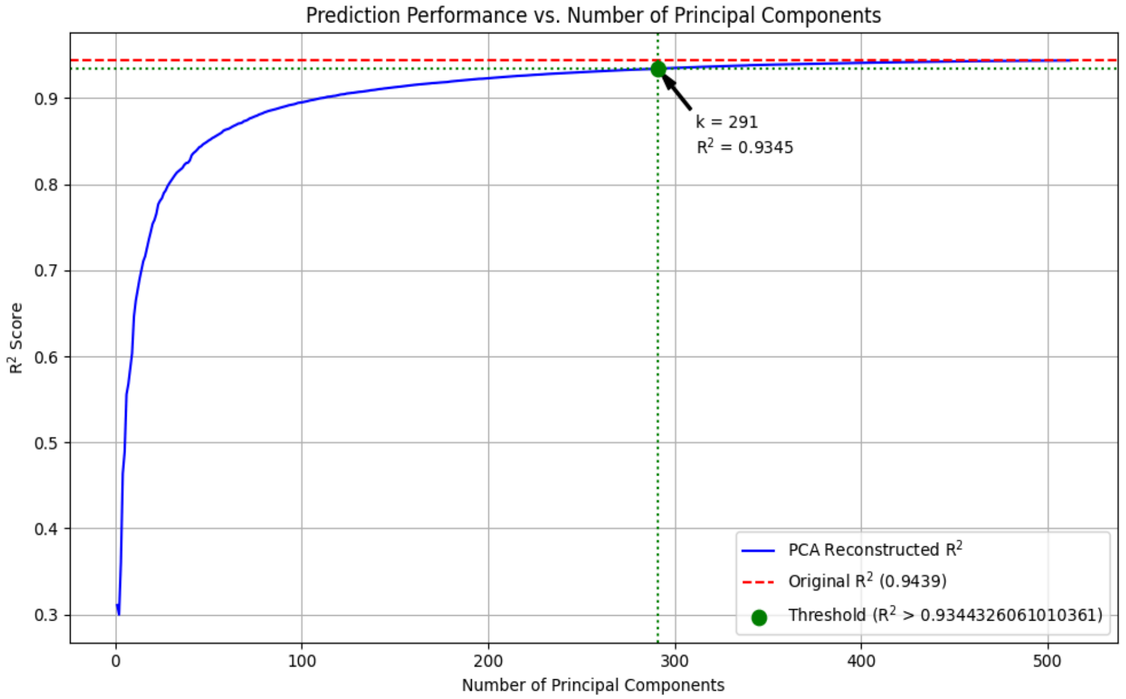
$$z' = D^{-\frac{1}{2}} E^{\top} z$$

PCAの時点で次元削減を行いたい

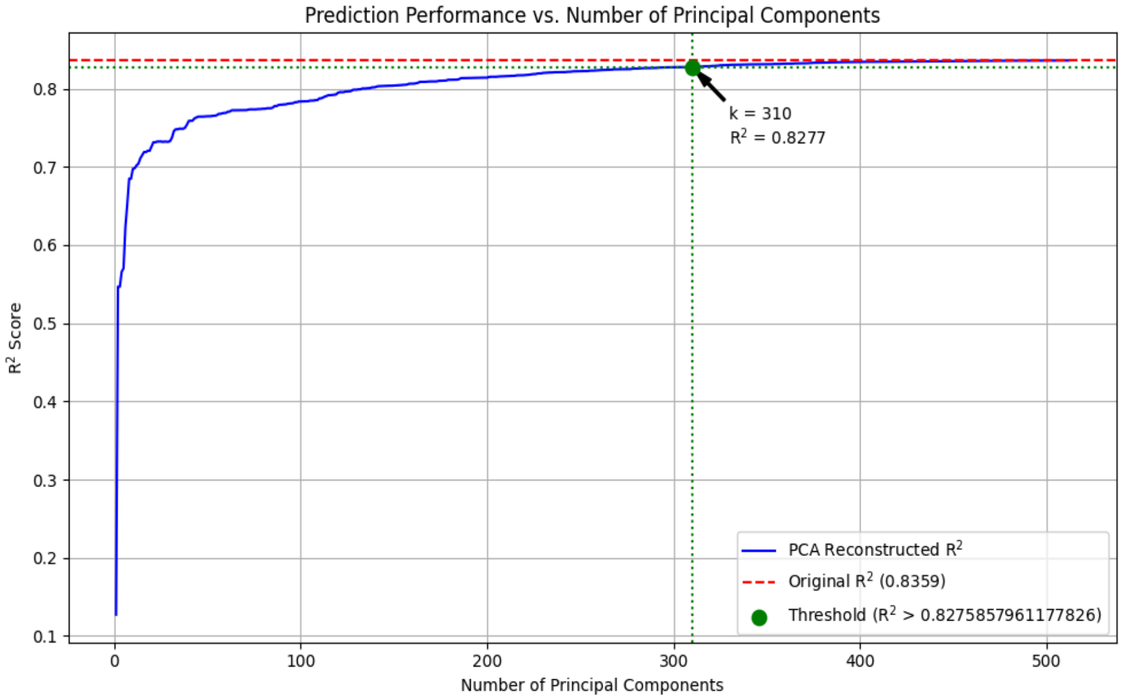
特定のR^2値を超えた時の主成分数まで次元削減

データセット全体計算したR^2値の99%に初めて届いた主成分数を採用

その次元数で白色化を行う



vgg16の主成分数とR^2値



resnet16の主成分数とR^2値

独立成分分析(2): 回転行列の推定

白色化された信号は無相感ではあるが独立ではない

変換後に互いに独立になるような回転行列を推定する

- FastICA: 各独立成分の非ガウス性を最大化する
- TDSEP: 独立成分間の時間遅れ共分散を対角化

FastICA

FastICAでは、信号 s の独立性はnegentropy $J(s)$ を用いて測られる

ただし、ν は平均0分散1の正規分布からのサンプル

$$J(s) = \sum_{p=1}^{2} k_p \left[E\{G_p(s)\} - E\{G_p(\nu)\} \right]^2$$

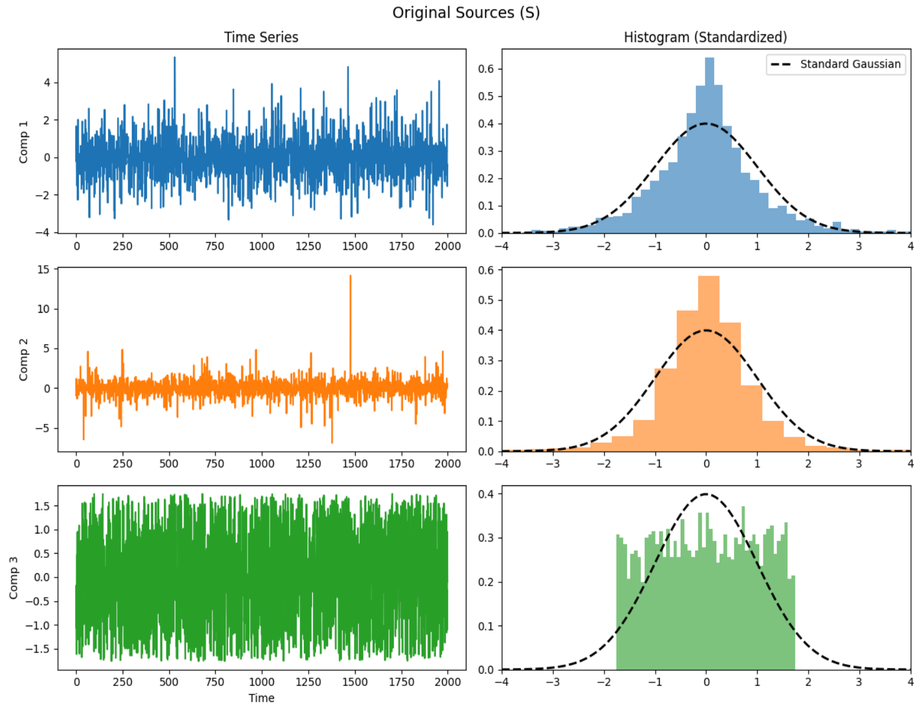
$$G_1(u) = \frac{1}{a_1} \log \cosh a_1 u$$

$$G_2(u) = -\exp\left(-\frac{u^2}{2}\right)$$

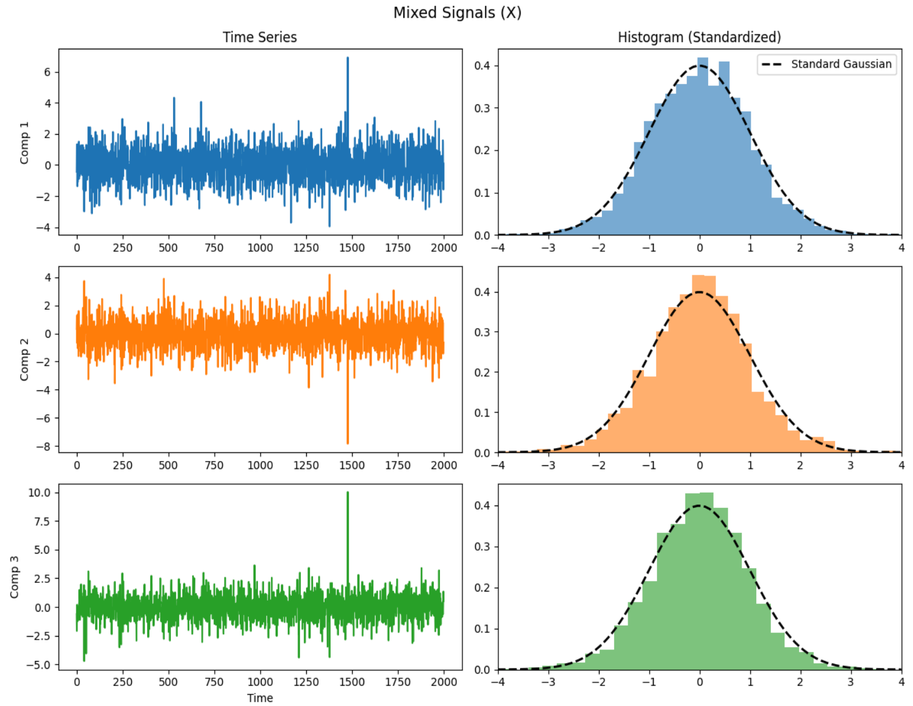
FastICA

negentropy$J(s)$は、sの分布がガウス分布と離れている度合を表す

独立な信号(標本)を混合するとその分布はガウス分布(点線)に近づく



信号源とそのヒストグラム

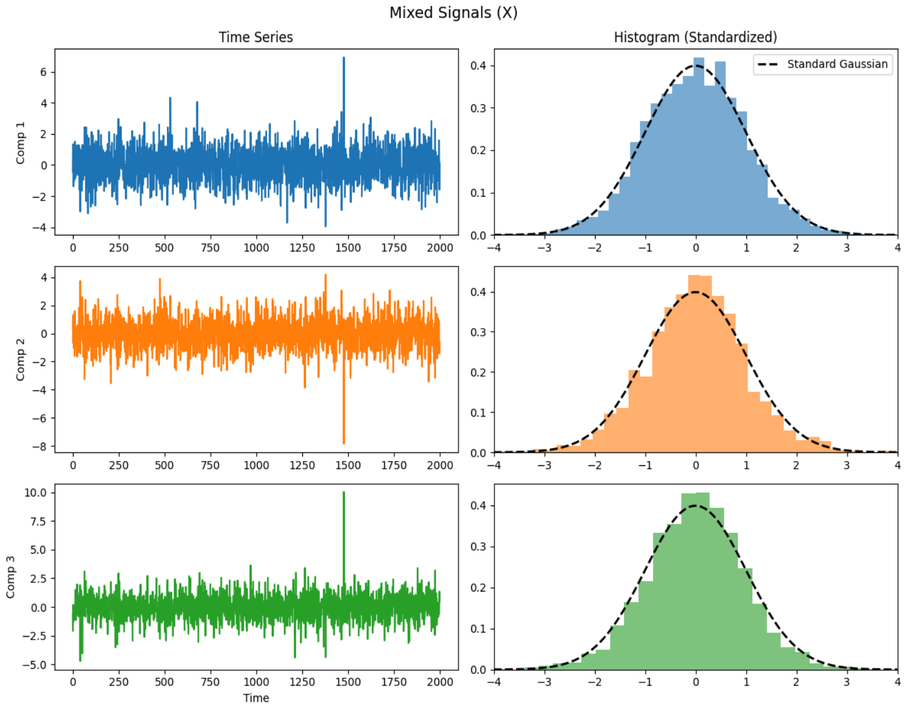


信号源を混合した観測信号とそのヒストグラム

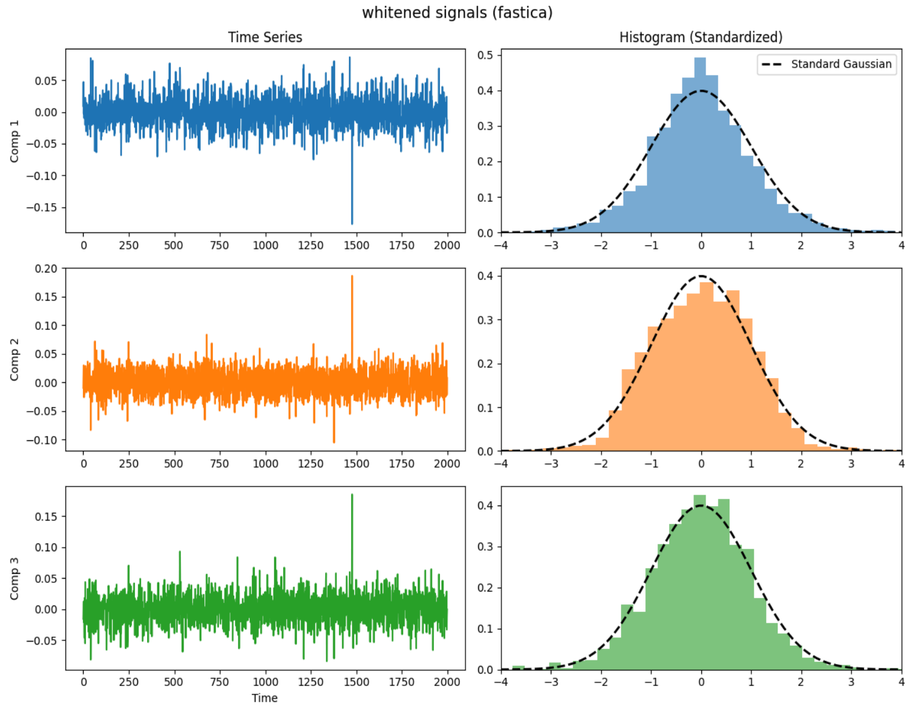
FastICA

negentropy$J(s)$は、sの分布がガウス分布と離れている度合を表す

観測信号を白色化すると無相関化はされるが分布はあまり変わらない



観測信号とそのヒストグラム

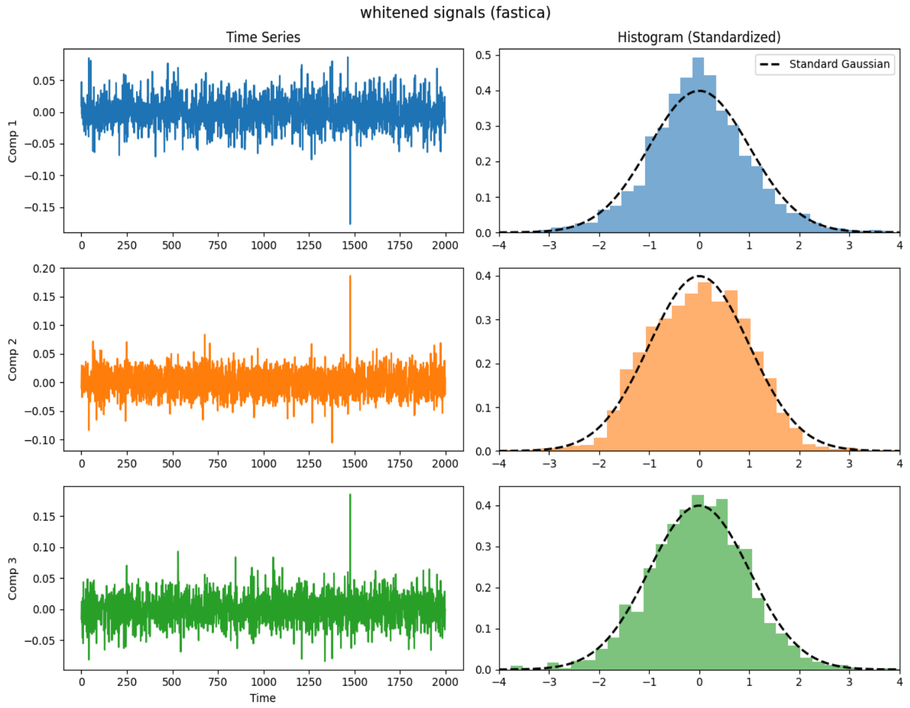


白色化した信号とそのヒストグラム

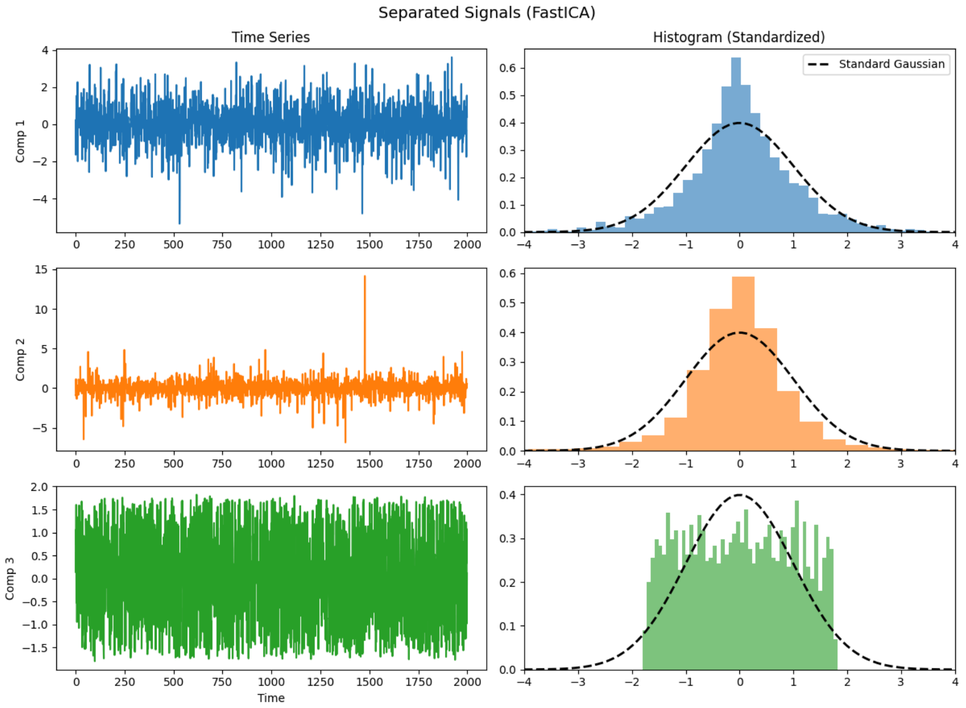
FastICA

negentropy$J(s)$は、sの分布がガウス分布と離れている度合を表す

FastICAで非ガウス性を最大化する回転を求め、信号源を推定



白色化した信号とそのヒストグラム



FastICAで非ガウス性を最大化した信号とそのヒストグラム

TDSEP

TDSEPでは、各独立成分の時間差共分散を独立性の指標として用いる

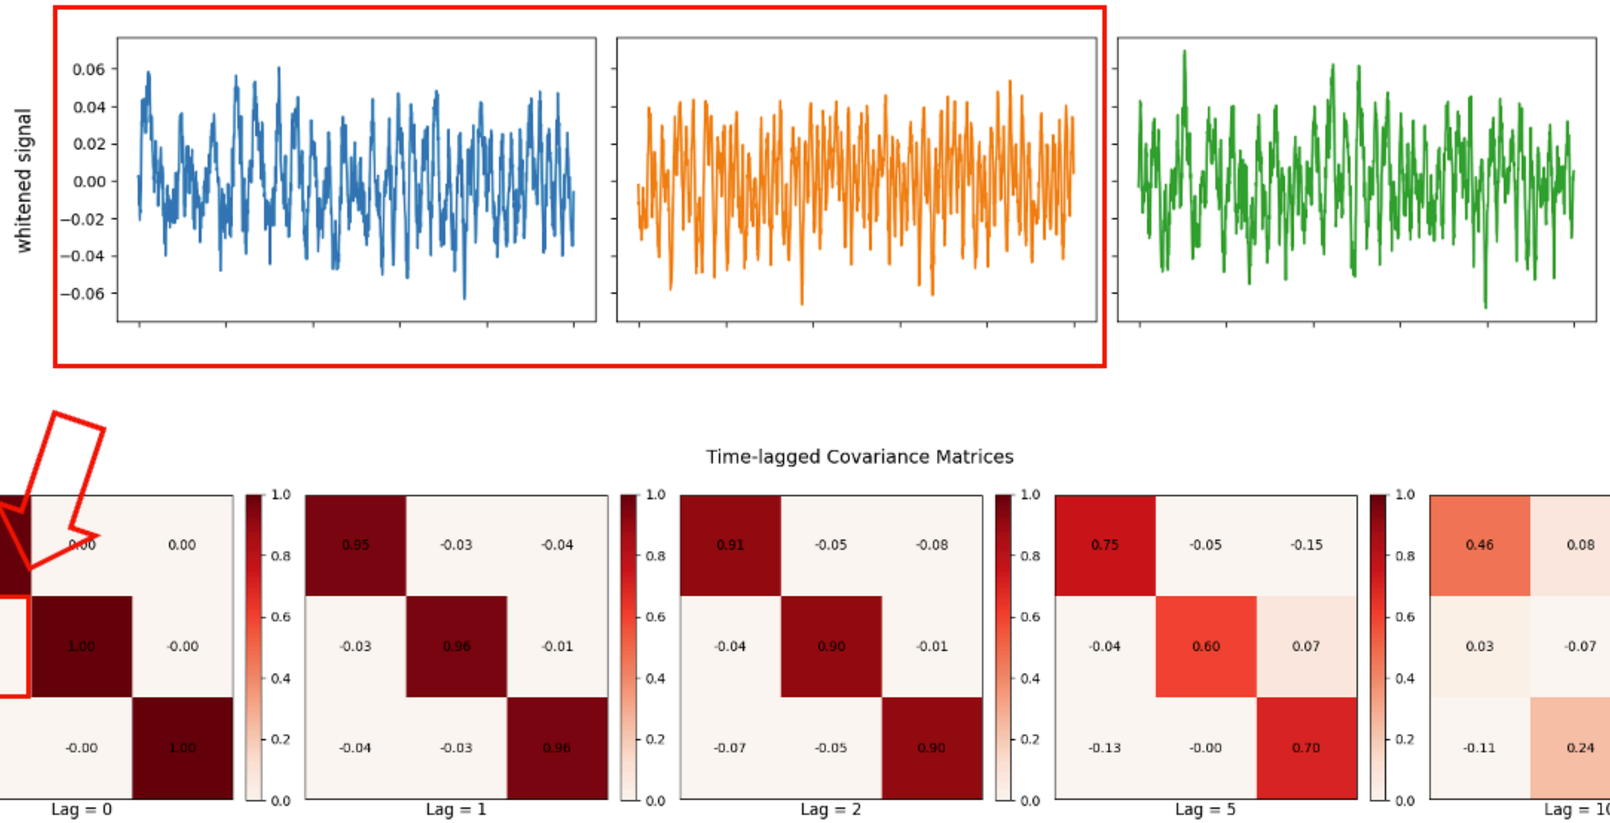
以下のコスト関数$l(W)$を最小化するようにWを最適化する

$$
\begin{aligned}
l(W_{ij}) &= \sum_{k=0}^{N} \sum_{i \neq j} E\{\boldsymbol{s}_i(t)\boldsymbol{s}_j(t+\tau_k)\}^2 \\
\boldsymbol{s}(t) &= W\boldsymbol{x}(t) \\
\tau_0 &= 0
\end{aligned}
$$

TDSEPにおける独立性

観測信号$\boldsymbol{x}(t)$がすでに白色化されているとする

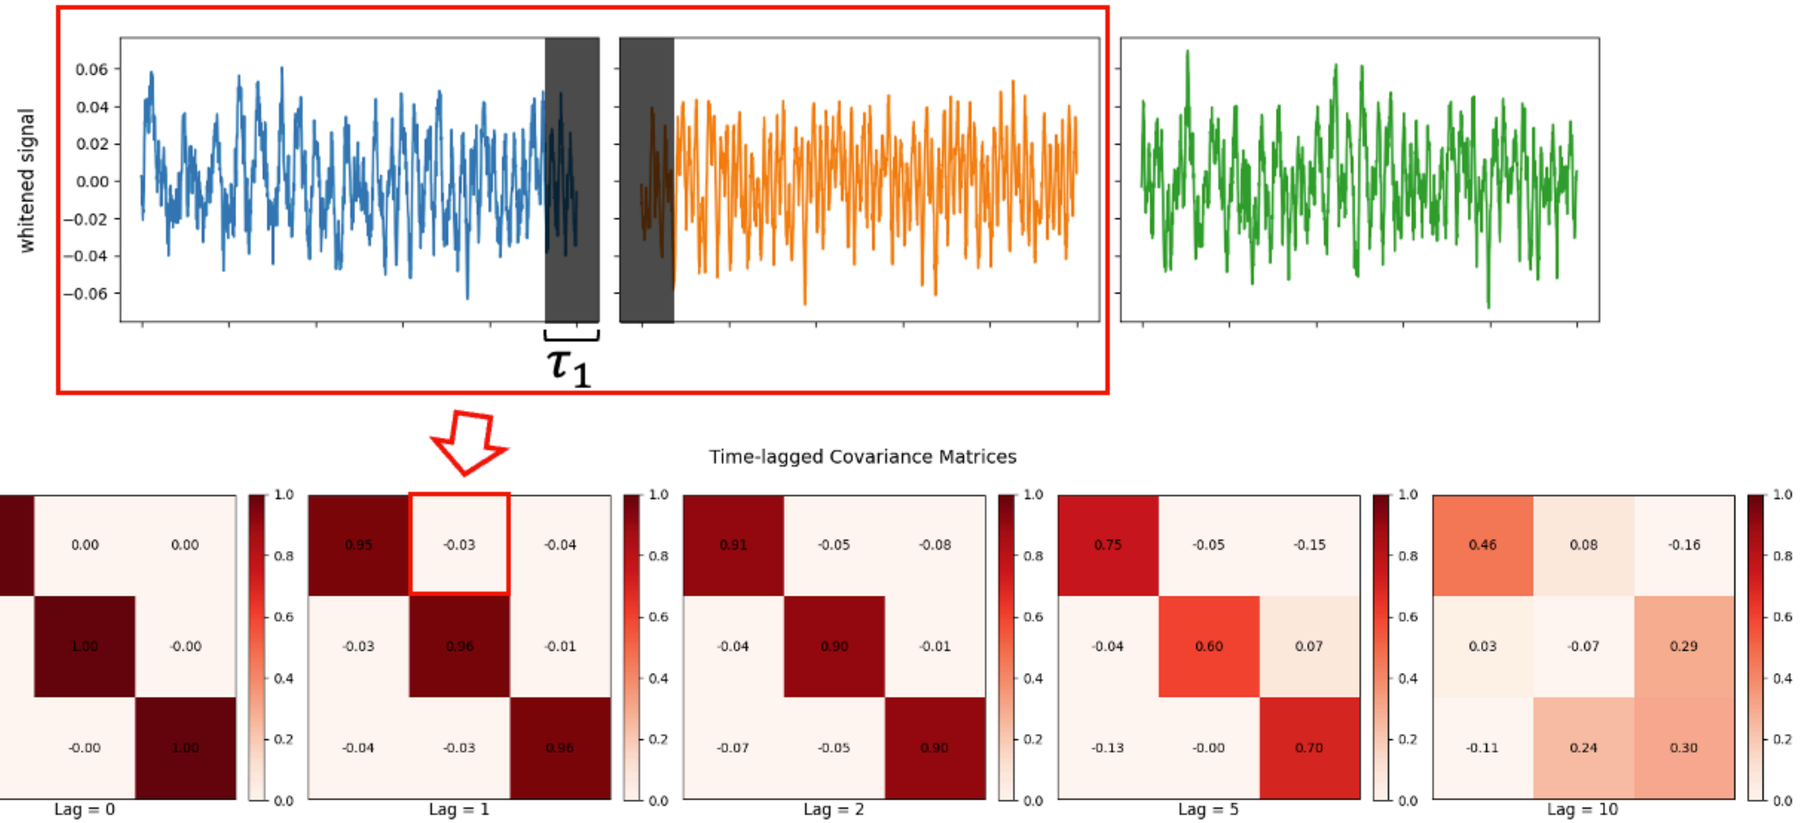
この場合、瞬時共分散(時間遅れなし)の非対角成分は0になっている



TDSEPにおける独立性

観測信号$\boldsymbol{x}(t)$がすでに白色化されているとする

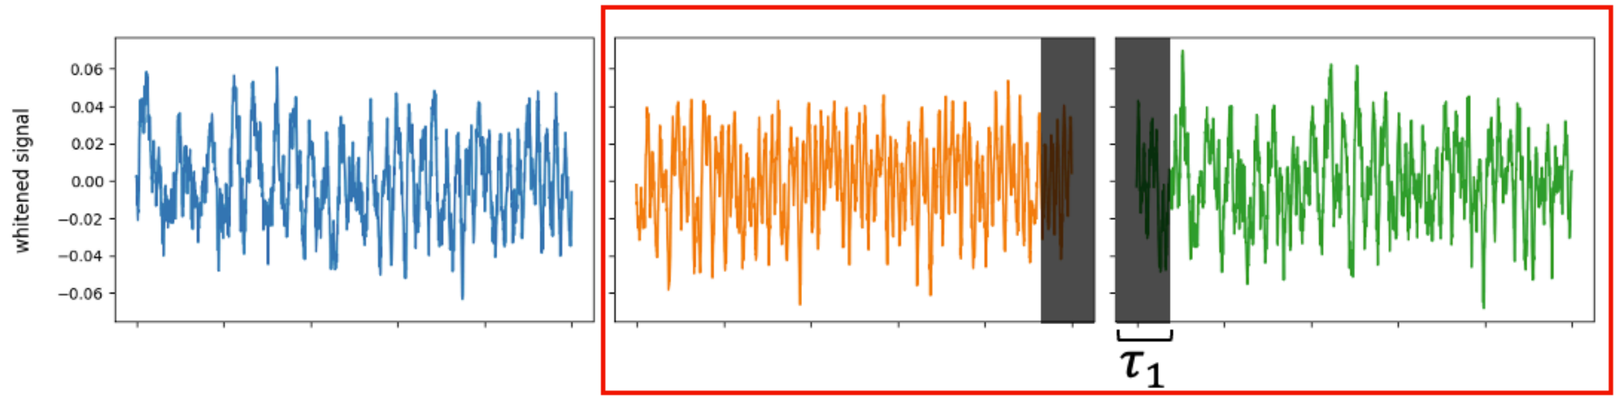
しかし、時間差共分散(時間遅れあり)の非対角成分は0にはならない

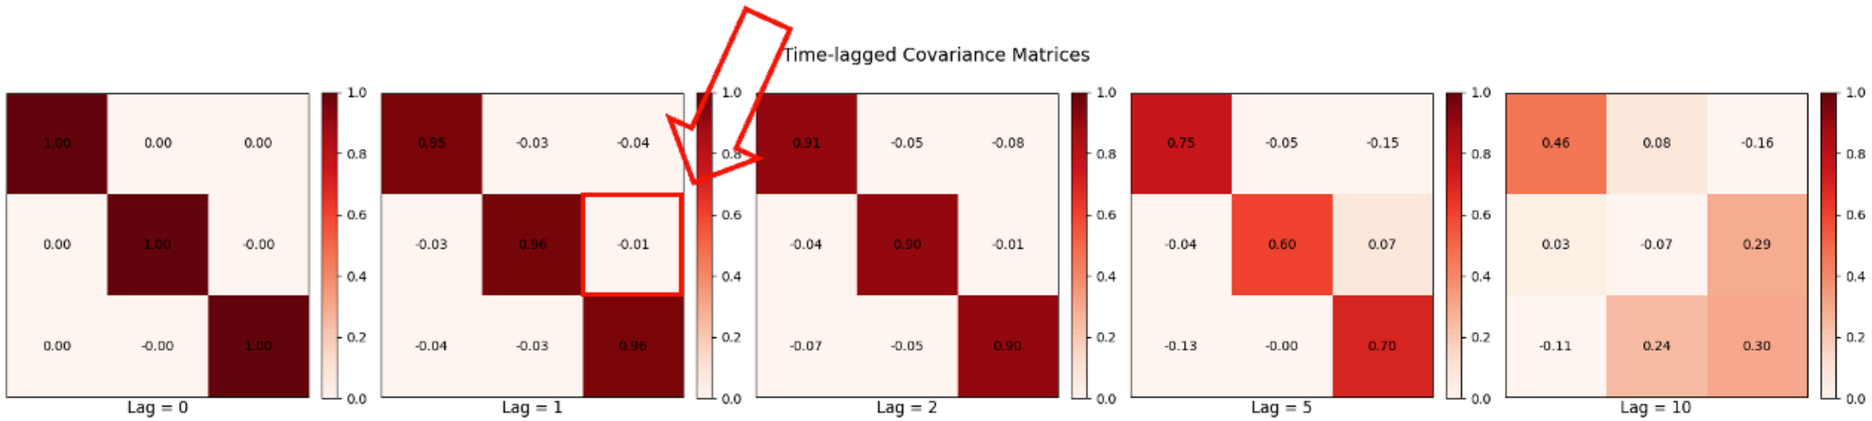


TDSEPにおける独立性

観測信号$\boldsymbol{x}(t)$がすでに白色化されているとする

しかし、時間差共分散(時間遅れあり)の非対角成分は0にはならない

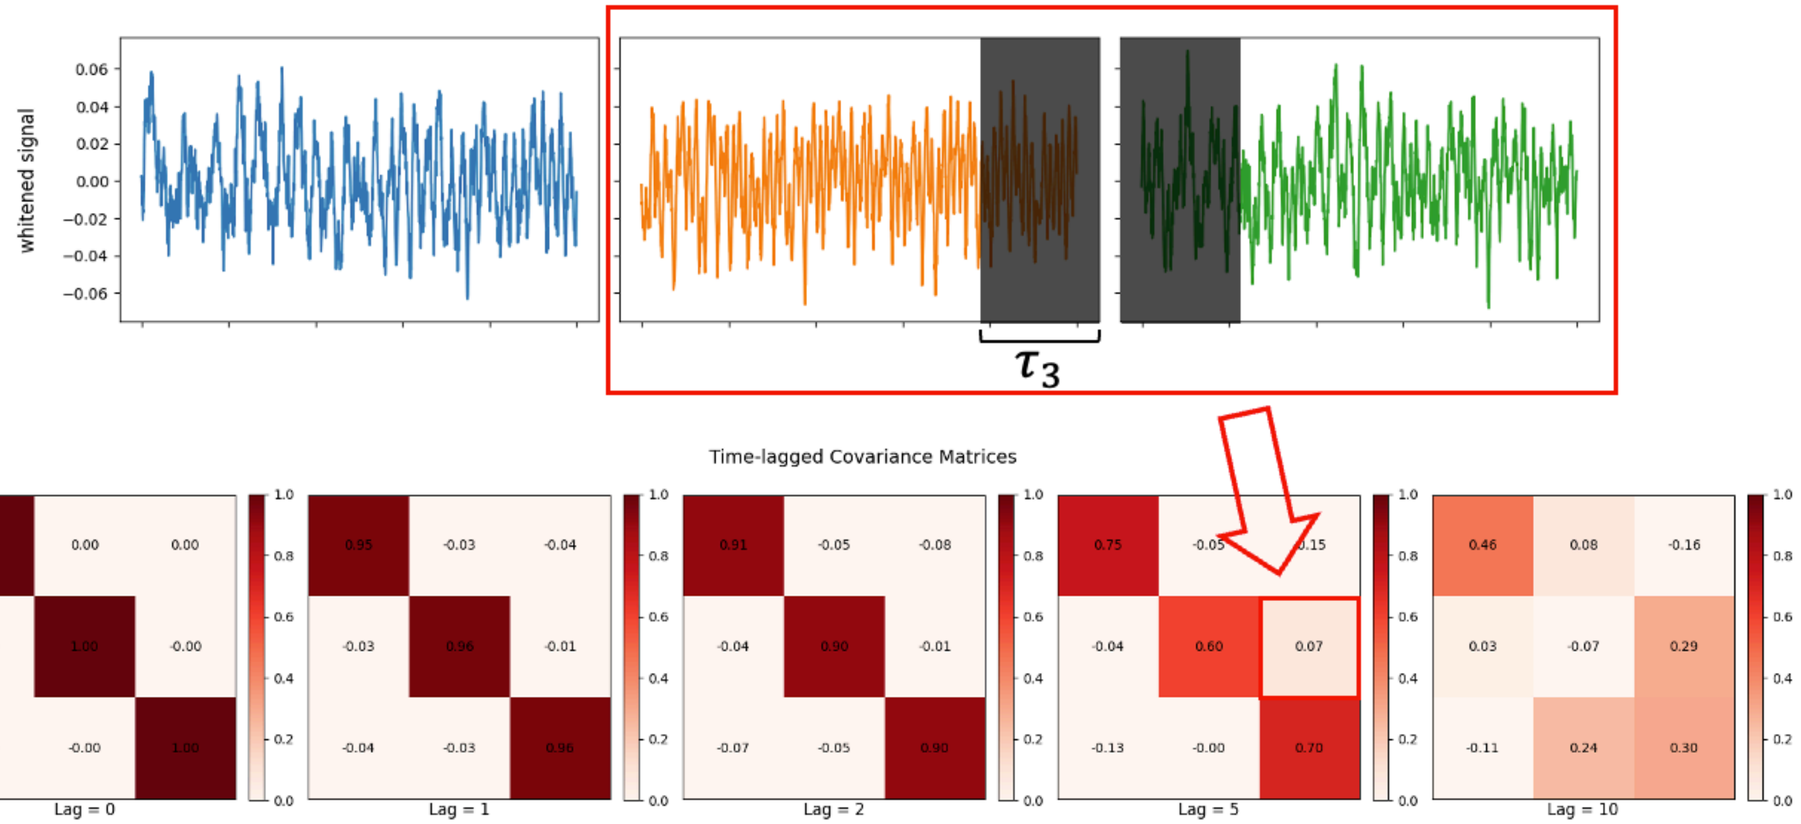




TDSEPにおける独立性

観測信号$\boldsymbol{x}(t)$がすでに白色化されているとする

しかし、時間差共分散(時間遅れあり)の非対角成分は0にはならない

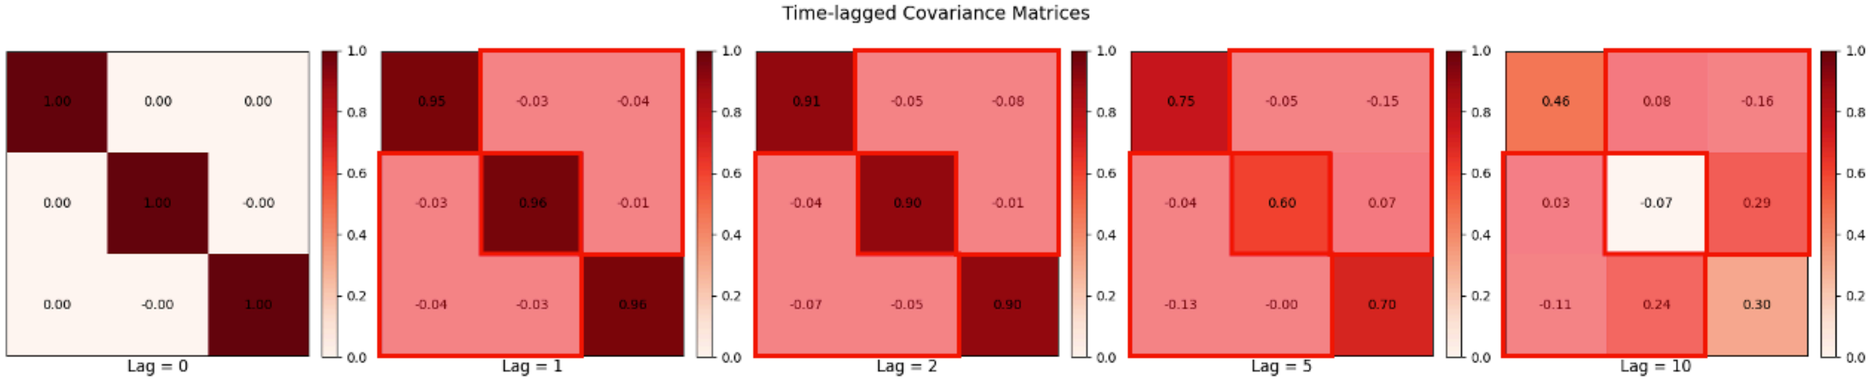


TDSEPにおける独立性

信号源は互いに独立であるため、相関を持たない

-> 時間差共分散の非対角成分を最小化するような回転を推定する

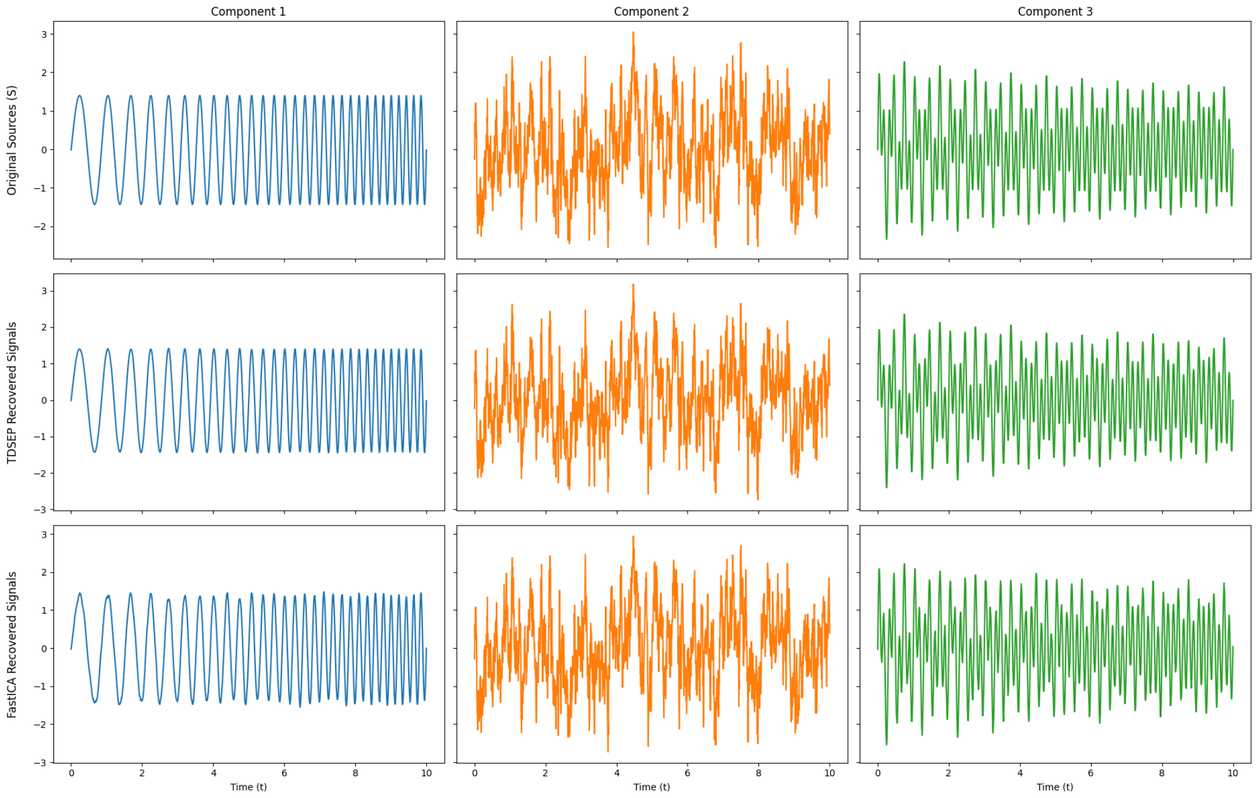
$$l(W_{ij}) = \sum_{k=0}^{N} \sum_{i \neq j} E\{s_i(t) s_j(t + \tau_k)\}^2$$



時系列データの混合に対する手法の比較

FastICAは各信号を標本として扱うが、TDSEPは時系列として扱う

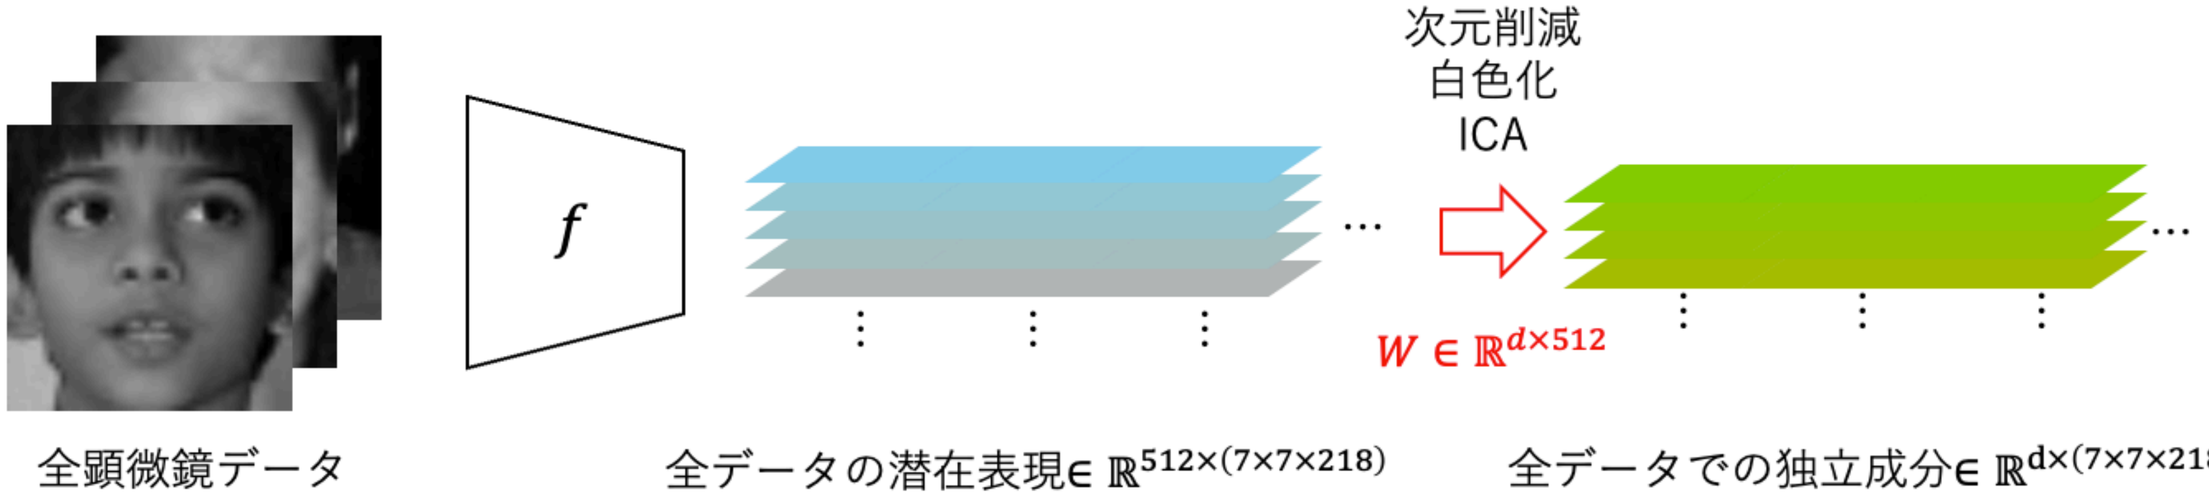
時系列データではTDSEPの方が良いこともある



上段:正解の信号元、中段:TDSEPで推定、下段:FastICAで推定

実験の全体像(1): 分離行列Wを推定

全ての顕微鏡画像の潜在表現を独立に分解するようなWを推定



実験の全体像(2): 推定したWを用いて画像分解

分離行列Wを各画像に適用し、得られた特徴を可視化

