# LLM の地図 LLM Atras

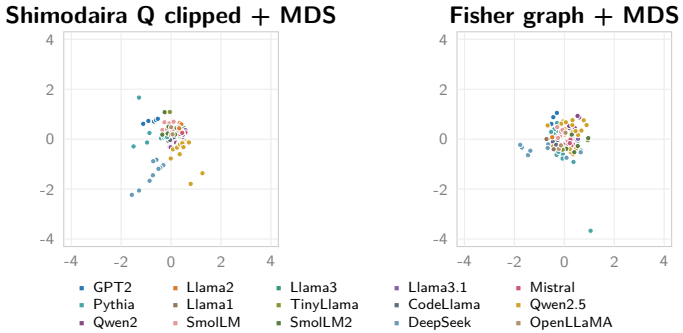
## 内部表現のグラフ構造に基づくモデル間距離の検討

赤塚育海

早稲田大学村田研究室

ゼミ発表資料

# 欲しい地図：見たい性質を比較したい




同じ 100 モデル・300 文章の実験結果。各点は LLM、色は系列。metric MDS（seed 0）、共通スケール。右は Fisher ＋正規化 Frobenius。

**地図の作り方は様々。見たい性質が分かりやすく比較できる地図が欲しい。**

- モデルの**出力の近さ**が分かるか？
- **内部構造の近さ**を反映できるか？
- モデルを**マージした際の性質・性能の予想**に役立つか？

# 研究の大枠：距離関数から地図を作る

$M$ 個の LLM に、同じ $n$ 件の文章 $x_1, \ldots, x_n$ を入力する。モデルを $i, j = 1, \ldots, M$ で区別し、モデル $i$ が文章 $x$ に与える生成確率を $p_i(x)$ と書く。




**課題は 2 つある。**

- 距離の意味：見たい性質が何で、見たい性質の意味で近くなっているか？
- 地図の忠実度：元のモデル間距離を、2 次元でも保てているか？

# 距離関数に求める性質

$D_{ij}$ はモデル $i, j$ の距離。$i, j, k$ はいずれも**モデルの番号**。

| | |
|---|---|
| $D_{ij} \geq 0$ | 距離は負にならない |
| $D_{ii} = 0$ | 自分自身との距離は 0 |
| $D_{ij} = D_{ji}$ | 比べる順序に依存しない |
| $D_{ik} \leq D_{ij} + D_{jk}$ | 遠回りより直接の距離が長くならない |

通常の距離では、さらに**異なる対象を距離 0 としない**ことも求める。

有限文章の特徴が一致しても LLM 自体の一致は保証できない。今回は、観測した特徴上の距離として扱う。

公理だけでなく、**見たい性質の意味で「似ている」を測ること**が必要。

# Shimodaira 法 (1)：KL 近似の仮定と意味

出力分布がどれくらい似ているかを比較したい場合、**KL ダイバージェンス**を思いつく。

**仮定：**両モデル $p_i, p_j$ は、文章の真の生成分布 $p_0$ の近傍にある [O25]。$r(x) = \log[p_i(x)/p_j(x)]$、$\mathbb{E}_i$ は $x \sim p_i$ での平均とする。

$$\mathrm{KL}(p_i, p_j) = \mathbb{E}_i[r], \qquad \underbrace{\mathbb{E}_i[e^{-r}] = 1}_{\text{生成確率の総和が 1}}$$

$e^{-r} \approx 1 - r + r^2/2$ と **2 次まで展開**して平均すると、

$$0 \approx -\mathbb{E}_i[r] + \tfrac{1}{2}\mathbb{E}_i[r^2] \quad \Longrightarrow \quad 2\,\mathrm{KL}(p_i, p_j) \approx \mathbb{E}_i[r^2].$$

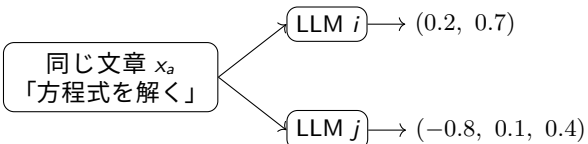
平均 $\mathbb{E}_i[r]$ はずれの 2 次、その二乗は 4 次。したがって 2 次近似では、$\mathbb{E}_i[r^2]$ を**分散**で置き換えられる。両モデルが $p_0$ に近いとき、平均を取る分布の違いも高次の補正となる。

$$\boxed{2\,\mathrm{KL}(p_i, p_j) \approx \mathrm{Var}_{x \sim p_0}[r(x)]}$$

**標本から計算できる：**$r(x) = \log p_i(x) - \log p_j(x)$ は対数尤度の差。共通の文章標本で $r(x)$ を求め、その分散を推定する。

# 前提知識：LLM の内部表現

LLM は文章をトークン列に分け、各層で情報を**多数の数値の並び＝ベクトル**として処理する。ここでは、文章から取り出すベクトルを**内部表現**と呼ぶ。




**モデル間で座標の意味や次元はそろわない。**

本研究のグラフでは、最終 attention の Value（各トークンの情報ベクトル）を、最後のトークンから向けた attention 重みで平均した**文章ベクトル** $\eta$ を使う。最終トークンの出力ベクトルを使う条件は **Hidden** と呼び、区別する。

# 先行研究：内部表現に基づく比較—CKA

CKA[K19] は、共通文章の**内部表現どうしの関係**を比較する。特徴次元が違っても、同じ文章対の内積を比べられる。

文章 $x_a$ の表現を $\eta_{i,a} \in \mathbb{R}^{d_i}$ とする（$i$：モデル、$a, b = 1, \ldots, n$：文章番号、$d_i$：特徴次元）。平均を引いて Gram 行列 $K_i$ を作る：

$$\bar{\eta}_i = \frac{1}{n} \sum_{a=1}^{n} \eta_{i,a}, \qquad K_i(a, b) = (\eta_{i,a} - \bar{\eta}_i)^\top (\eta_{i,b} - \bar{\eta}_i).$$

$K_i(a, b)$ は中心化した文章 $a, b$ の表現の内積。$\top$ は転置。

**大きさを 1 にそろえた Gram 行列どうしのユークリッド距離を、距離関数として採用する。**

$$d_{\mathrm{CKA}}(i, j) = \left\| \frac{K_i}{\|K_i\|_F} - \frac{K_j}{\|K_j\|_F} \right\|_F.$$

$\|K\|_F$ は全成分の二乗和の平方根。原論文の CKA 類似度を距離化して表示。

**解釈：**文章対の内積のパターンが似ているモデルほど近い。一様な拡大・縮小や直交変換には不変。

上式は $\eta$ 表現での定義。主実験の参照条件 Hidden + CKA では、$\eta_{i,a}$ を最終層・最終トークン表現 $h_{i,a}$ に置き換える。

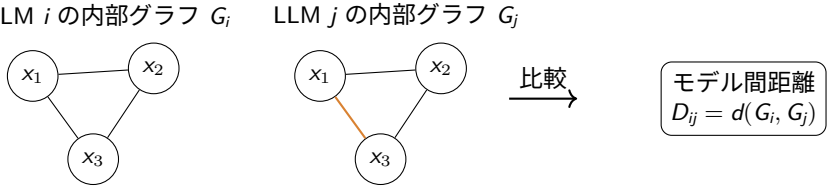
# 先行研究と今回の比較条件

| 方法 | 比較する対象 | 位置づけ |
|---|---|---|
| Shimodaira[O25] | 共通テキストの対数尤度 | 参照手法 |
| CKA[K19] | 内部表現の関係構造 | 参照手法 |
| **Euclidean グラフ** | Euclidean 辺長によるグラフ | **提案手法（Euc）** |
| **Fisher グラフ** | Fisher 計量による辺長のグラフ | **提案手法（Fisher）** |

**両方が本研究で構成するモデル間距離。**Euc 版は、Fisher 計量の効果を切り分ける比較対象としても用いる。

既存の計量・グラフ比較法を用いた構成であり、各構成要素自体を新規と主張するものではない。

# 提案手法：テキスト間のグラフで LLM を表す




**構築：**共通文章を各 LLM に入力し、文章の内部表現を得る。各文章から近い $k$ 文章を結ぶ **kNN 疎グラフ**を作る。

**比較：**グラフ間の距離を定義し、$d(p_i, p_j) := d(G_i, G_j)$ としてモデル間距離を作る。グラフは、文章間の関係を通して埋め込み空間の性質を反映している。

**グラフの比較方法と、 グラフの作り方に工夫する余地がある。**まず比較方法を紹介し、次に構築方法を説明する。図は 3 文章による模式図。

# グラフ比較法：地図に何が表れるかの仮説

**見たい性質に応じてグラフの距離を選べばよいので、拡張性が高い。**

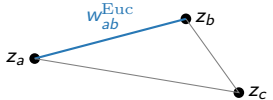
| 比較法 | 比較するもの | 地図に表れると考える性質（仮説） |
|---|---|---|
| 非正規化 Frobenius | 同じ文章対の距離の値 | 文章表現の広がりが近いモデルのまとまり |
| 正規化 Frobenius | スケールを除いた距離配置 | 全体の関係構造が近いモデルのまとまり |
| Rank | 文章対の距離順位 | 距離の大きさによらず、文章の近さの順序が似るモデル |
| kNN overlap | 各文章の近傍の顔ぶれ | 局所的な文章の分類・まとまり方が似るモデル |
| NetLSD | グラフの拡散・接続構造 | 文章の対応を超えて、全体の接続形状が似るモデル |
| Gromov–Wasserstein 距離 | 対応を探索した内部距離構造 | 文章の対応が異なっても、関係の形が似るモデル |

仮説は能力・学習データの一致を直接意味しない。今回の GW は近似計算。Frobenius・Rank・kNN は共通文章の対応を使用し、NetLSD は使用せず、GW は対応を探索する。数式は Appendix。

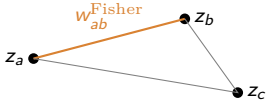
# グラフ構築：Euclidean と Fisher の比較

ここでは **1 つの LLM** を固定する。$a, b, c$ は文章の番号、$z_a, z_b \in \mathbb{R}^{16}$ は文章 $x_a, x_b$ の表現 $\eta$ を PCA で 16 次元にしたベクトル。

Euclidean：通常の長さ




Fisher：場所・方向による重みを反映




$$w_{ab}^{\mathrm{Euc}} = \|z_a - z_b\|_2, \qquad w_{ab}^{\mathrm{Fisher}} = \sqrt{(z_a - z_b)^\top \frac{M_a + M_b}{2}(z_a - z_b)}.$$

$w_{ab}$ は文章 $a, b$ をつなぐ辺の長さ。$M_a$ は文章 $a$ の位置での Fisher 計量（$16 \times 16$ 行列）。各文章点での計量は、我々の先行研究 Akatsuka, Murata[AM] の手法で計測できる。接続先は Euclidean 近傍 20 件で共通にし、辺長だけを変更する。図は 2 次元で模式化。経由する辺長の合計が最小のものを**最短路距離**とする。

# Fisher 計量の特徴：テキスト近傍のカテゴリ対応

**ここでのカテゴリ＝入力文章に付けられた分野ラベル。**数学・生物学・政治など 15 分野であり、**LLM の系列ラベルではない**。

各文章について、グラフ最短路で近い 10 文章の中に**同じ分野の文章が何件あるか**を数え、全文章・100 モデルで平均した。

| 辺長 | 同分野の近傍割合 |
|---|---|
| Euclidean | 13.58% |
| Fisher | **16.01%** |

**読み取り：**Fisher では、文章の近傍が分野ラベルと対応しやすくなった。

グラフ構築に関する補助的な観察。カテゴリ全体のシルエット値は両条件とも負で、明確な全体分離やモデル地図の優位性までは示していない。

# 実験設定：テキストと LLM

## 英語テキスト：15 分野 ×20 件＝ 300 件

生物学、ビジネス、計算機科学、経済学、教育、工学、文学、数学、医学、哲学、物理学、政治、プログラミング、心理学、テクノロジー。

全モデルに同じ文字列を入力。すべての tokenizer で特殊トークン込み最大 512 トークンとなる共通接頭部を使用。

元集合：保存済みカテゴリ付きテキスト。取得元の書誌情報は要確認。

## LLM：15 系列・100 モデル

| | | | |
|---|---|---|---|
| Qwen2.5 | 20 | Mistral | 14 |
| Pythia | 12 | DeepSeek | 9 |
| Llama2 | 6 | Qwen2 | 6 |
| SmolLM | 6 | SmolLM2 | 6 |
| GPT2 | 5 | CodeLlama | 4 |
| Llama3.1 | 3 | OpenLLaMA | 3 |
| Llama3 | 2 | Llama1 | 2 |
| TinyLlama | 2 | | |

ベース・指示調整・コード・数学向けなどを含む。系列は派生を含む実験用分類。

# 実験設定：比較条件と評価指標

- グラフ用文章表現 $\eta$ を PCA で 16 次元にする。接続先は Euclidean 近傍 20 件。
- Euclidean ／ Fisher の辺長と 6 比較法を組み合わせて 12 条件。Shimodaira 法（Q clipped：二重中心化後）と Hidden ＋ CKA の参照 2 条件を加え、計 14 条件。
- MDS は**元の距離関係をなるべく保って LLM を 2 次元に配置する方法**。入力行列の非対角成分の平均を 1 にそろえ、同じ条件で適用。

**モデル間距離の意味：最近傍同系列率**
元の距離行列で、各 LLM に最も近い別の LLM を 1 つ選ぶ。同系列だった LLM の数を 100 で割る。例：88% なら 100 モデル中 88 モデル。

MDS：2 次元・metric、4 初期値、最大 500 反復。乱数 seed を変えた 10 実行の平均を報告。推論は 75 モデルが FP16、25 モデルが FP32（各モデル内で特徴と尤度の精度を共通化）。

# 地図の評価：2 次元化による情報損失

$D_{ij}$ は**次元削減前のモデル間距離**、$y_i \in \mathbb{R}^2$ は地図上の LLM $i$ の位置。$\widehat{D}_{ij} = \|y_i - y_j\|_2$ は**地図上の点間距離**とする。

**Stress：距離の再現誤差。小さいほどよい。**

$$\mathrm{Stress} = \min_{c>0} \sqrt{\frac{\sum_{i<j}(D_{ij} - c\widehat{D}_{ij})^2}{\sum_{i<j} D_{ij}^2}}.$$

$c$ は図全体の拡大率を調整する係数、$i < j$ は各モデル対を 1 回だけ数える指定。0 なら、拡大率を除いて元の距離を完全に再現。

**距離順位相関：元の距離と地図の距離の順序が一致するか。**
全モデル対の $D_{ij}$ と $\widehat{D}_{ij}$ の Spearman 順位相関を求める。1 なら近い／遠いの順位が一致。
**能力や系列との相関ではない。**

どちらも**地図化で失われた情報**の指標であり、元の距離が目的に適しているかは評価しない。

# 主実験：全 14 条件の比較（同系列率順）



| 距離関数 | 最近傍同系列率 ↑ | MDS Stress ↓ | 距離順位相関 ↑ |
|---|---|---|---|
| Euclidean + Rank | 90% | 0.347 | 0.770 |
| Hidden + CKA | 90% | 0.288 | 0.849 |
| Euclidean + 正規化 Frob. | 88% | 0.311 | 0.766 |
| Euclidean + 非正規化 Frob. | 88% | 0.055 | 0.972 |
| Euclidean + kNN | 88% | 0.377 | 0.550 |
| Fisher + Rank | 88% | 0.346 | 0.772 |
| Fisher + 非正規化 Frob. | 87% | 0.032 | 0.960 |
| Fisher + kNN | 86% | 0.370 | 0.596 |
| Shimodaira Q clipped | 86% | 0.143 | 0.967 |
| Fisher + 正規化 Frob. | 85% | 0.257 | 0.828 |
| Euclidean + 近似 GW | 62% | 0.271 | 0.878 |
| Fisher + 近似 GW | 61% | 0.206 | 0.847 |
| Euclidean + NetLSD | 43% | 0.018 | 0.999 |
| Fisher + NetLSD | 37% | 0.028 | 0.998 |

同系列率は**次元削減前**の距離行列で評価し、降順に表示。MDS 指標は 10 実行平均。
同率の表示順に優劣はない。系列一致と 2 次元再現精度は別の性質。

# 今後の展望：地図の目的と評価方法を確立する

**まず「何のための地図か」を決め、その目的に合う評価方法を確立する。**

系列が近い地図、コーパスの変更に頑健な地図、教師選択に役立つ地図では、評価基準が異なる。

| 目的 | 追加する評価指標の候補 |
|---|---|
| コーパスの変更に対してロバスト性がある | 文章の出典・分野・文体を変えたときの、モデル間距離の順位相関・k 近傍一致率 |
| 蒸留・マージに活用する | 距離を使った教師選択の性能改善／マージ後の性能の予測誤差 |
| 近傍探索に使える地図にする | k 近傍保存率、Trustworthiness（偽の近傍が少ないか）、Continuity（元の近傍を失わないか）[LV09] |
| 再現可能な地図にする | 文章の再抽出・MDS 初期値・グラフ設定の変更に対する距離順位と近傍の安定性 |

地図作成に使わない問題で検証し、規模・総合正答率・系列の影響を切り分ける。目的の評価と次元削減の忠実度を分けて比較する。

# まとめ

- **100 モデル・300 テキスト・14 条件**でモデル間距離を比較した。
- Akatsuka, Murata の Fisher 計量を用いると、テキスト近傍のカテゴリ対応が改善した。
- モデル系列との対応では、一貫した改善は見られなかった。
- 系列一致率と MDS の再現精度は一致せず、評価の分離が必要。

**議論ポイント：**地図の評価方法の方針、距離関数の手法について。

# Appendix A：LLM 比較の先行手法—CKA

$i, j$ はモデル、$x_a$ は共通文章（$a = 1, \ldots, n$）。モデル $i$ の文章表現を行に並べた行列を $F_i \in \mathbb{R}^{n \times d_i}$ とする。$d_i$ は特徴次元 [K19]。

$$H = I_n - \tfrac{1}{n}\mathbf{1}_n\mathbf{1}_n^\top, \quad K_i = HF_iF_i^\top H, \quad \mathrm{CKA}(i,j) = \frac{\langle K_i, K_j\rangle_F}{\|K_i\|_F\|K_j\|_F}.$$

$I_n$：単位行列、$\mathbf{1}_n$：全成分 1 の列ベクトル。$H$：各特徴の文章平均を引く中心化行列。$K_i(a, b)$：中心化後の文章対の内積。

$A, B$ を同サイズの行列として、$\langle A, B\rangle_F = \sum_{a,b} A_{ab}B_{ab}$、$\|A\|_F = \sqrt{\sum_{a,b} A_{ab}^2}$。今回の距離は

$$d_{\mathrm{CKA}}(i,j) = \|K_i/\|K_i\|_F - K_j/\|K_j\|_F\|_F = \sqrt{2(1 - \mathrm{CKA}(i,j))}.$$

**解釈：**座標の次元が違っても、共通文章間の関係を比較できる。回転・一様拡大に不変。

Hidden は最終層の最終トークン表現、$\eta$ は attention で重み付けした Value の平均。零ノルムの場合は上式を定義できない。

# Appendix B：グラフ間距離—記号と比較設定

| 記号 | 意味 |
|---|---|
| $i, j$ | 比較する LLM の番号 |
| $n$、$a, b$ | 共通文章数と文章の番号（$1$〜$n$） |
| $G_i$ | モデル $i$ の内部表現から作った文章グラフ |
| $S_i(a, b)$ | $G_i$ 上の文章 $a, b$ 間の最短路距離 |
| $P = n(n-1)/2$ | 異なる文章の組の総数 |
| $\widetilde{S}_i$ | 平均最短路距離を $1$ に正規化した行列 |

$$\widetilde{S}_i = S_i \Big/ \left( \frac{1}{P} \sum_{a<b} S_i(a, b) \right).$$

$\|v\|_2 = \sqrt{\sum_r v_r^2}$ はベクトル $v$ の長さ、$\top$ は転置。$a < b$ は各文章対を $1$ 回だけ数える指定。
**モデル間距離 $D_{ij}$ と、文章間距離 $S_i(a, b)$ は別物**。今回 $n = 300$。

# Appendix C：グラフ間距離—Frobenius

**非正規化：距離スケールも比較**

$$d_{\mathrm{raw}}(i,j) = \sqrt{\frac{1}{P}\sum_{a<b}\big(S_i(a,b) - S_j(a,b)\big)^2}$$

**正規化：相対的な距離配置を比較**

$$d_{\mathrm{norm}}(i,j) = \sqrt{\frac{1}{P}\sum_{a<b}\big(\widetilde{S}_i(a,b) - \widetilde{S}_j(a,b)\big)^2}$$

$S_j = cS_i$（$c > 0$）なら正規化後は距離 0。いずれも差の二乗を用いるため、大きな差が結果に強く影響する。

# Appendix D：グラフ間距離—Rank

**Rank ＝順位。**文章数を $n$、異なる文章対の数を $P = n(n-1)/2$ とする。モデル $i$ のグラフ最短路距離 $S_i(a, b)$（$a < b$）を、**距離が小さい順に 1 位から $P$ 位まで順位付け**する。同じ値には平均順位を与える。

**順位ベクトル $r_i \in \mathbb{R}^P$：**文章対を全モデル共通の順番に並べ、その各対に対応する順位を格納したもの。順位順に並べ替えたベクトルではない。

例：文章対を $(1,2), (1,3), (2,3)$ の順とし、距離が $(0.8, 0.2, 0.5)$ なら、$r_i = (3, 1, 2)$。最も近い対 $(1,3)$ の成分が 1 となる。

$$\widehat{r}_i = \frac{r_i - \bar{r}_i \mathbf{1}}{\|r_i - \bar{r}_i \mathbf{1}\|_2}, \qquad d_{\mathrm{rank}}(i,j) = \|\widehat{r}_i - \widehat{r}_j\|_2 = \sqrt{2(1-\rho_{ij})}.$$

$\bar{r}_i$ は順位の平均、$\mathbf{1}$ は全成分 1 の $P$ 次元ベクトル、$\|\cdot\|_2$ はベクトルの長さ。平均を引いて長さを 1 にそろえる。$\rho_{ij}$ は順位ベクトル間の Spearman 相関。

**意味：**距離の値そのものを捨て、**どの文章対が相対的に近い／遠いか**を比較する。同じ順位なら距離 0。各文章から見た順位ではなく、全文章対を通した順位を使う。

全距離が同値なら中心化後の長さが 0 となり、上式は定義できない。

# Appendix E：グラフ間距離—kNN overlap

$i, j$ はモデル、$a = 1, \ldots, n$ は文章の番号。$N_i^k(a)$ は、最短路距離で文章 $a$ に近い別の $k$ 文章の集合。$|\cdot|$ は集合の要素数。

$$d_{\mathrm{kNN}}(i, j) = 1 - \frac{1}{n} \sum_{a=1}^{n} \frac{|N_i^k(a) \cap N_j^k(a)|}{k}$$

- 近傍が完全一致すると 0、共通近傍がなければ 1。
- 近傍内の順序、距離の大きさ、遠方の関係は使用しない。
- 比較の近傍数は $k = 10$。**グラフ構築の $k = 20$ とは別**。

# Appendix F：グラフ間距離—NetLSD

モデル $i$ の文章グラフの辺長を $w_{ab}$（$a, b$ は文章番号）とする。接続済みの辺だけ、近いほど大きい重み $A_i(a, b)$ に変換する。

$$A_i(a,b) = \exp\left[-\frac{1}{2}\left(\frac{w_{ab}}{\mathrm{median}(w)}\right)^2\right], \quad L_i = I_n - B_i^{-1/2} A_i B_i^{-1/2}.$$

$\mathrm{median}(w)$ は全辺長の中央値。$B_i$ は行和を対角に持つ行列、$I_n$ は $n$ 次単位行列、$L_i$ は正規化ラプラシアン。

$$h_i(t) = \frac{1}{n}\sum_{r=1}^{n} e^{-t\lambda_{i,r}}, \qquad d_{\mathrm{NetLSD}}(i,j) = \sqrt{\sum_{t\in\mathcal{T}} (h_i(t) - h_j(t))^2}.$$

$\lambda_{i,r}$ は $L_i$ の $r$ 番目の固有値。$t$ は拡散時間、$\mathcal{T}$ は $10^{-2}$〜$10^{2}$ の対数間隔 128 時点。$h_i(t)$ が拡散構造の要約になる。

接続していない辺の $A_i(a, b)$ は 0。同じスペクトルの別グラフは識別できない。Tsitsulin et al., KDD 2018. `https://arxiv.org/abs/1805.10712`

# Appendix G：グラフ間距離—GW

$i, j$ はモデル、$a, b$ はモデル $i$ 側、$c, d$ はモデル $j$ 側の文章番号。$\widetilde{S}_i$ は平均 1 に正規化した文章間の最短路距離行列。

$$d_{\mathrm{GW}}(i,j) = \sqrt{\min_{T \in \Pi(u,u)} \sum_{a,b,c,d} |\widetilde{S}_i(a,b) - \widetilde{S}_j(c,d)|^2 \, T_{ac} \, T_{bd}}.$$

$T_{ac}$ は文章 $a$ と文章 $c$ の対応の重み。$u = (1/n, \ldots, 1/n)^\top$ は各文章を等しく扱う重みで、許される対応の集合は

$$\Pi(u,u) = \{ T \geq 0 : T\mathbf{1}_n = u, \;\; T^\top \mathbf{1}_n = u \}.$$

$\mathbf{1}_n$ は全成分 1 の列ベクトル。$T \geq 0$ は全要素が非負の意味。

**解釈：**「$a$ と $b$ の近さ」を「対応候補 $c$ と $d$ の近さ」と比べ、全体の不一致が最小になる対応を探す。1 対 1 対応に限らない。

今回は POT で最大 100 反復、両方向の目的値の平均の平方根を使用。大域最適性は保証されず、少数の三角不等式違反を観測。`https://pythonot.github.io/gen_modules/ot.gromov.html`

# Appendix H：KL から分散へ—正規化とテイラー展開

2 つの分布で確率が正の共通範囲を考え、$r(x) = \log[p_j(x)/p_i(x)]$ と置く。$\mathbb{E}_i$ は $x \sim p_i$ での平均、$\varepsilon$ は分布のずれの小ささを表す。

$$\mathbb{E}_i[e^{r(x)}] = \sum_x p_i(x) \frac{p_j(x)}{p_i(x)} = \sum_x p_j(x) = 1.$$

$r$ が小さく、平均したテイラー剰余が $O(\varepsilon^3)$ になる正則性を仮定すると、

$$e^r = 1 + r + \tfrac{1}{2} r^2 + 3 \text{ 次以降}, \qquad 0 = \mathbb{E}_i[r] + \tfrac{1}{2}\mathbb{E}_i[r^2] + O(\varepsilon^3).$$

$\mathrm{KL}(p_i, p_j) = -\mathbb{E}_i[r]$ なので、

$$2\mathrm{KL}(p_i, p_j) = \mathbb{E}_i[r^2] + O(\varepsilon^3) = \mathrm{Var}_i(r) + (\mathbb{E}_i[r])^2 + O(\varepsilon^3).$$

$\mathbb{E}_i[r] = O(\varepsilon^2)$ より、その二乗は 4 次。2 次まで残すと $2\mathrm{KL} \approx \mathrm{Var}_i(r)$。**平均が消える理由は確率の正規化**である。$O(\varepsilon^k)$ は $\varepsilon$ の $k$ 乗程度以下の項を表す。

# Appendix I：Fisher 情報・共通分布との対応

異なる LLM を含む共通の滑らかな分布族 $p(x;\theta)$ を考える [O25]。$\theta$ はこの**補助的な分布族の座標**で、LLM 同士の重みを直接引き算するものではない。

$$p_i = p(\cdot;\theta), \quad p_j = p(\cdot;\theta+\delta), \quad s_\theta(x) = \nabla_\theta \log p(x;\theta), \quad I(\theta) = \mathbb{E}_i[s_\theta s_\theta^\top].$$

$\delta$ は小さい座標差、$s_\theta$ は対数確率の変化率（スコア）、$I$ は Fisher 情報行列。正則性の下で $\mathbb{E}_i[s_\theta] = 0$。

$$r(x) = \delta^\top s_\theta(x) + O(\|\delta\|^2), \quad \mathrm{Var}_i(r) = \delta^\top I(\theta)\delta + O(\|\delta\|^3).$$

よって前頁と合わせて $2\mathrm{KL} = \delta^\top I\delta + 3$ 次以降。

さらに $p_i, p_j$ が**ともに** $p_0$ **の** $\varepsilon$ **近傍**にあれば、$r^2$ は 2 次、平均分布を $p_i$ から $p_0$ へ変える影響は正則性の下で 3 次となる。

$$2\mathrm{KL}(p_i, p_j) = \mathrm{Var}_{p_0}[\ell_i - \ell_j] + O(\varepsilon^3).$$

分散は符号反転で不変。$\ell_i = \log p_i$。本編の近似には局所性と正則性が必要。厳密な補助分布族の構成は原論文 Appendix D 参照。

# Appendix J：標本分散と中心化—省略しない計算

$\Delta_a = \ell_i(x_a) - \ell_j(x_a)$ を文章 $a$ での対数尤度差とする。$\bar{\Delta} = \frac{1}{n}\sum_a \Delta_a = \bar{\ell}_i - \bar{\ell}_j$ なので、

$$\begin{aligned}\widehat{v}_{ij} &= \frac{1}{n}\sum_{a=1}^{n}(\Delta_a - \bar{\Delta})^2 \\ &= \frac{1}{n}\sum_{a=1}^{n}\left[(\ell_i(x_a) - \bar{\ell}_i) - (\ell_j(x_a) - \bar{\ell}_j)\right]^2 \\ &= \frac{1}{n}\sum_{a=1}^{n}(c_{ia} - c_{ja})^2.\end{aligned}$$

$\bar{\ell}_i$ はモデル $i$ の文章平均、$c_{ia}$ は中心化した対数尤度。

モデル数 $M$、モデル番号 $m$ として、$q_{ia} = c_{ia} - \frac{1}{M}\sum_{m=1}^{M} c_{ma}$ と二重中心化しても、**共通項が引かれるため** $q_{ia} - q_{ja} = c_{ia} - c_{ja}$。

**解釈例：**文章ごとの差がすべて同じなら分散は 0。Q 距離は平均尤度の水準差を除き、文章間の相対的な得手不得手を比べる。

$1/n$ は経験分布の分散（不偏推定の $1/(n-1)$ とは区別）。母分散との対応には標本の代表性が必要。本実験は 15 分野を均等抽出しており、自然な文章分布そのものではない。

# Appendix K：文章表現と Fisher 計量の抽出

モデルを固定する。文章 $a$ のトークン数を $T_a$ とし、$t = 1, \dots, T_a$ はトークン番号。$v_{at}$ は最終 attention の Value ベクトル、$\alpha_{at} \geq 0$ は最後のトークンから各トークンへの attention（ヘッド平均、和 1）。

$$\eta_a = \sum_t \alpha_{at} v_{at}, \qquad z_a = P^\top (\eta_a - \mu).$$

$\mu$ は全文章の $\eta$ の平均、$P$ は上位 16 主成分を列に持つ PCA 射影行列。$\tilde{v}_{at} = P^\top v_{at}$、$\bar{v}_a = \sum_t \alpha_{at} \tilde{v}_{at}$ として、

$$C_a = \sum_t \alpha_{at} (\tilde{v}_{at} - \bar{v}_a)(\tilde{v}_{at} - \bar{v}_a)^\top, \quad M_a = (C_a + \gamma_a I_{16})^{-1}.$$

$C_a$ は重み付き共分散。期待値座標での Fisher 計量を逆共分散から推定する [AM]。$I_{16}$ は単位行列、$\gamma_a = 10^{-3} \operatorname{tr}(C_a)/16$ は数値安定化の正則化量、$\operatorname{tr}$ は対角和。

PCA・平均・計量はモデルごとに計算。最終層の出力そのものを使う Hidden 条件とは異なる。

# Appendix L：安定性評価—テキスト部分集合

300 件から 240 件を抽出し、グラフを再構築する評価を 20 回実施。

300 件での距離行列と 240 件で作り直した距離行列について、同じ 100 モデルの全モデル対を比較する。

| 距離関数 | 元のモデル間距離との順位相関 |
|---|---|
| Shimodaira Q clipped | $0.9987 \pm 0.0010$ |
| Euclidean ＋正規化 Frobenius | $0.9946 \pm 0.0013$ |
| Fisher ＋正規化 Frobenius | $0.9909 \pm 0.0033$ |

グラフ距離も高い安定性を示したが、今回の条件では Shimodaira 法がより安定。

平均 $\pm$ 標準偏差。PCA と局所計量は固定。入力分野の変更や、特徴処理から再計算した場合の安定性は未検証。

# Appendix M：見たい性質を、どう検証するか



**現状：同系列率は「出自」、Stress・順位相関は「2 次元化の忠実度」を評価。各手法が狙う性質そのものは、以下の独立評価が必要。**

| 手法 | 地図で見たい性質 | 反映されているかを確かめる方法（提案） |
|---|---|---|
| 非正規化 Frobenius | 文章表現の広がり | 平均文章間距離の差とモデル間距離の対応を測る。表現を一様拡大する対照も用意する。 |
| 正規化 Frobenius | スケールを除いた関係構造 | 独立文章の距離配置も似るか検証。一様拡大で不変か確認する。 |
| Rank | 文章の近さ・遠さの順序 | 独立文章でも文章対の近さの順序が一致するモデルが近いか測る。 |
| kNN overlap | 局所的な文章のまとまり方 | 独立文章の分野・意味ラベルに対する近傍パターンの類似と対応するか測る。 |
| NetLSD | 全体の接続・拡散形状 | 成分数・ボトルネックなど既知の構造を変えた対照グラフで、距離と地図上の変化を確認する。 |
| Gromov–Wasserstein | 対応に依存しない関係の形 | ノードを並べ替えても近さが保たれ、構造を変えると遠ざかるか対照グラフで確認する。 |
| Shimodaira Q | 文章ごとの相対的な尤度傾向 | 未使用文章での尤度傾向の類似を予測できるか測る。 |
| Hidden ＋ CKA | 文章表現の内積関係 | 未使用文章での内積関係の類似を予測できるか測る。 |

既知の変換・対照グラフは設計通りの挙動の確認、未使用文章は汎化の確認。いずれも能力との対応を直接保証しない。元のモデル間距離と 2D 地図上の距離の両方で評価し、次元削減の影響を分ける。

# 参考文献



M. Oyama, H. Yamagiwa, Y. Takase, H. Shimodaira.
Mapping 1,000+ Language Models via the Log-Likelihood Vector. ACL, 2025.
https://aclanthology.org/2025.acl-long.1584/


S. Kornblith, M. Norouzi, H. Lee, G. Hinton.
Similarity of Neural Network Representations Revisited. ICML, 2019.
https://proceedings.mlr.press/v97/kornblith19a.html


J. A. Lee, M. Verleysen.
Quality assessment of dimensionality reduction: Rank-based criteria. Neurocomputing, 72, 1431–1443, 2009.

https://doi.org/10.1016/j.neucom.2008.12.017


I. Akatsuka, N. Murata.
The Geometry of Foundation Model Latent Spaces. 2026. 手元原稿。